

济南市政务服务智能问答系统开发报告

目录

一、项目概述	4
（一）项目背景	4
（二）应用行业	4
（三）算法或模型优势	4
二、解决方案	5
（一）方案设计	5
1. 数据采集（Python）	5
2 数据清洗（Python）	6
3. 智能体搭建阶段（Coze）	6
（二）方案功能	6
1. 轻量化数据支撑功能	6
2. 智能体问答功能	6
3. 意图归一化与适配功能	7
（三）关键技术	7
1. 数据采集模块技术	7
2. 数据清洗模块技术	7
3. 智能体模块技术	7
（四）算法实现过程	8
1. 数据采集环节实现	8
2. 数据清洗环节实现	9
3. 智能体搭建与问答环节实现	9
（五）结果分析	9
1. 准确率和召回率	9

2. 数据完整性与质量	10
3. 运行效率与稳定性	11
三、应用价值	11
（一）经济效益	11
（二）社会效益	11
四、 算法使用步骤与示例	12
（一） 数据采集	12
1. 概述	12
2. 环境配置	12
3. 数据采集流程	13
4. 数据采集指导与示例	14
5. 附件与数据字段	15
6. 注意事项	15
（二） 数据清洗	15
1. 算法（脚本功能）说明	15
2. 使用说明	16
（三） 智能体问答系统搭建	17
1. 工作原理	17
2. 使用方法	18
3. 可能的配置选项	19
4. 使用示例	19

一、项目概述

（一）项目背景

济南市政务服务网(<http://zwfw.jinan.gov.cn/>)作为济南市“一网通办”平台，提供了丰富的政务服务事项信息，包括事项名称、办理流程、所需材料等关键内容。但这些信息以非结构化形式分散呈现，导致人工采集整合低效，难成标准化数据集；更制约“智能问答系统”的构建——系统因无结构化数据源，需人工整理信息，不仅更新滞后、易出错，还难以精准解析用户诉求。因此，开发“智能问答系统”势在必行：先通过自动化数据采集模块，将非结构化数据转化为规范、实时的知识库；再以知识库赋能智能体，提升其语义解析与匹配索引和精准应答能力，最终打通政务服务“问查”链路，优化市民体验。

（二）应用行业

1. 电子政务领域

直接服务于政府网站数据整合与分析，为政务数据开放和共享提供技术支持；

2. 智慧城市建设

作为城市级政务服务数据平台的重要组成部分，支持“数字政府”建设；

3. 数据分析与决策支持

为政府部门提供业务流程优化、服务效能评估的数据依据；

4. 第三方信息服务

为开发政务服务导航 APP、智能问答系统等第三方应用提供数据基础。

（三）算法或模型优势

1. 智能反爬处理能力

采用 cloudscraper 技术栈，能够智能应对现代网站常见的 JavaScript 反爬机制，相比普通 HTTP 请求库成功率显著提高。该技术能模拟真实浏览器行为，处理 cookies、执行 JavaScript 片段，有效绕过 Cloudflare 等复杂反爬系统，大幅提升爬取成功率，确保政务数据稳定采集，为智能体知识库提供连续、完整的源头数据，避免智能体因数据缺失导致应答不准，为后续智能体所需的高质量数据采集提供稳定支撑。

2. 精准数据提取机制

设计了专门的表格信息提取算法，能够从复杂 HTML 结构中精准定位关键信

息通过“标签-值配对+DOM 导航”算法，从复杂 HTML 中精准提取结构化政务数据，避免误判。标准化数据可直接供智能体调用，助力智能体快速匹配用户关键词，减少应答偏差，实现“爬取精准-智能体高效”协同。


3. Coze 智能体高效搭建优势

依托 Coze 平台搭建政务智能体，相比传统代码开发模式，具备显著优势：一是操作便捷性，无需复杂编程基础，通过可视化界面拖拽组件、配置规则即可完成智能体搭建，降低开发门槛；二是流程透明性，智能体的知识库关联、关键词匹配逻辑、问答响应规则等均清晰可见，便于后期调试与优化；三是协同适配性，可直接对接前期数据爬取模块输出的结构化数据集，快速构建“爬取-存储-调用”链路，实现智能体知识库的自动更新与精准检索，提升系统整体响应效率。

二、解决方案

（一）方案设计

本解决方案以“数据采集-数据清洗-智能体问答系统的搭建”为核心流程，构建“爬取数据直接适配智能体应用”的闭环体系，各环节深度衔接，确保数据价值高效转化，具体如下：



1. 数据采集（Python）

利用 Python 的 requests 库进行会话初始化与 API 参数配置，发送请求获取列表页数据；再通过 BeautifulSoup 等解析库，从列表页中提取详情页链接，进而精准爬取详情页数据，完成原始数据的采集工作。

2 数据清洗 (Python)

以 Python pandas 库为核心，用 drop_duplicates() 去重复、dropna() 处理空值去噪；统一日期、单位等格式并转 UTF-8 编码标准化；通过自定义规则校验数据准确性。

3. 智能体搭建阶段 (Coze)

在 Coze 平台上，构建并对接知识库，将清洗后的数据转化为知识内容存储其中；配置语义解析模块，使智能体能够准确理解用户输入的语义和意图；设计问答流程，让智能体可以根据用户问题，从知识库中检索知识并生成合适的应答。

(二) 方案功能

1. 轻量化数据支撑功能

系统能够自动爬取济南市政务服务网 55 页范围内的 600+ 个事项数据。通过空页检测终止无效请求，支持周期更新并生成日志，为智能体知识库提供完整的数据源，保证智能体应答的实效性。

2. 智能体问答功能

(1) 语句精准解析：依托 Coze 大模型与政务预训练语料，能精准识别用户模糊或口语化表述（如“退休多缴社保怎么退”），剔除冗余信息后提取“社保退费”“退休”等核心关键词，同时适配“一网通办”的政务简称，通过同义词映射与意图预判，确保关键词提取准确性，避免表述差异导致的匹配偏差。

(2) 高效检索匹配：将解析后的核心关键词（如“社保退费申报”）传入知识库检索接口，快速匹配爬取的政务数据，精准定位关联事项，筛选出包含事项名称、办理地点、申请材料等在内的完整信息，保障检索结果与用户需求的关联性。

(3) 规范化答复生成：对检索到的事项数据，大规模预设模版自动抽取事项名称、办理地点、咨询方式等关键字段，剔除冗余内容后按规范化格式整合信息（如办理材料、办理时间），向用户返回清晰、规整的政务答复，无需人工二次整理。

3. 意图归一化与适配功能

智能体在处理用户问题时，可自动对口头语化表述（如“咋退多交的社保”）、简称（如“个体户执照办理”）进行意图归一化，转化为标准检索关键词（如“社保退费”“个体工商户营业执照办理”），确保不同表述方式下均能精准匹配知识库数据，提升问答适配性。

（三）关键技术

1. 数据采集模块技术

聚焦稳定获取政务原始数据，为智能体知识库提供源头支撑，核心技术包括：

（1）cloudscraper 反爬处理技术：可智能应对 JavaScript 挑战与浏览器指纹验证，自动执行网站所需 JavaScript 片段、维护有效 cookies 与会话状态，模拟真实浏览器行为绕过 Cloudflare 等复杂反爬系统，确保政务数据持续稳定采集，避免因爬取中断导致智能体数据库缺失或过时。

（2）HTML 解析与 DOM 导航技术：通过 CSS 选择器精确定位“受理条件”“申请材料”等智能体核心所需信息的容器元素；利用元素父子/兄弟关系进行 DOM 导航，规避网页结构微调导致的提取失败；对事项名称、办理地点等核心字段实施多层存在性检查，提取失败时自动触发重试，减少数据缺失。

2. 数据清洗模块技术

聚焦数据标准化处理，确保数据可直接适配智能体应用，核心技术为数据结构化技术：

（1）设计含 11 个关键字段的结构化字典，字段定义与智能体知识库的 Schema（数据模型）完全对齐，（如“业务办理项编码”对应智能体的“事项唯一标识符 ID”，“咨询方式”对应智能体的“联系信息”），无需二次映射即可直接导入；

（2）使用 utf-8-sig 编码解决 Excel 中文乱码问题，同时确保生成的 JSON 格式数据能被智能体正常读取，避免因编码问题导致的信息乱码。

3. 智能体模块技术

依托专业平台构建智能体问答能力，实现数据到服务的转化，具体如下：

（1）核心平台

基于 Coze 平台搭建智能体，借助平台可视化配置能力，降低开发门槛，同

时实现与前期采集清洗数据的无缝对接。

（2）平台内核心技术


①语义解析技术：依托 Coze 大模型的政务领域训练语料与上下文分析能力，精准识别用户模糊/口语化表述中的核心诉求，提取关键检索词，适配政务简称与口语化表达；

②知识库检索技术：通过 Coze 平台检索接口，将解析后的关键词与结构化知识库数据快速匹配，提升智能体检索效率；

③答复生成技术：利用 Coze 大模型的提示词优化与字段抽取能力，按预设模版从检索结果中提取关键信息，剔除冗余后按规范化格式整合，生成清晰答复。

（四）算法实现过程

算法实现过程通过“数据采集环节-数据清洗环节-智能体搭建环节”为核心流程，具体的操作流程如下图所示：



1. 数据采集环节实现

围绕“稳定获取政务原始数据”展开，为智能体知识库提供基础素材，核心步骤如下：

（1）会话与参数准备：建立模拟浏览器会话，设置高度仿真的 HTTP 请求头，解析起始页面提取 theme、deptCode 等隐藏函数，构建 API 参数字典，确保 API 调用通过服务器验证，同时为后续按分类爬取、支撑智能体分类打基础。

（2）列表与详情页获取：调取事项列表专用 API，循环更新页码参数；通过 CSS 选择器提取事项名称、详情 URL 及分类代码，构建“事项名称-详情 URL-分类代码”索引表并规范化 URL；将索引表存储为 JSON 文件，作为智能体知识库的“事项索引”，便于智能体快速定位目标事项。

2. 数据清洗环节实现

聚焦“数据标准化处理”，确保数据适配智能体使用，核心步骤如下：

（1）关键信息结构化：解析详情页时，清洗事项名称与编码以适配智能体语义匹配；开发表格提取函数，定位“办理地点”等标签单元格并获取对应值，合并清洗多行文本；通过双通道收集电话，用多模式正式匹配并去重格式化。

（2）数据整合优化：提取受理条件内容，清洗材料名称；将所有结构化数据按智能体知识库列顺序排列，填充缺失值；生成 CSV 文件（人工核查）与 JSON（智能体直读），JSON 以“事项编码为键”存储，用 utf-8-sig 编码避免乱码。

3. 智能体搭建与问答环节实现

依托清洗后的数据构建问答能力，实现“数据-服务”转化，核心步骤如下：

（1）知识库搭建：将清洗后的 JSON 文件直接导入智能体，以“事项编码为键”的结构构建知识库，结合前期“事项名称”，形成“分类检索+键值对快速定位”的双检索体系，支撑智能体高效查找数据。

（2）问答流程实现：用户提问后，智能体先调用语义解析模块，基于政务预训练语料提取核心关键词（如从“退休社保多缴怎么退”提“社保退费”“退休”）；在通过关键词匹配“事项索引”，定位目标事项名称；最后根据名称调取 JSON 知识库中对应的办理地点、材料、咨询方式等，按预设模版格式化输出，完成精准应答。

（五）结果分析

1. 准确率和召回率

(1) 定义 TP、FN、FP、TN

①TP（真阳性）：正类问题→预测正确（本应答对，实际答对）；

②FN（假阴性）：正类问题→预测错误（本应答对，实际答错）；

③FP（假阳性）：负类问题→预测正确（本应答错，实际冒充答对）；

④TN（真阴性）：负类问题→预测错误（本应答错，实际答错）。

(2) 准确率（Precision）：预测正确的结果中，真正正确的比例

公式：准确率 = $TP / (TP + FP)$

(3) 召回率（Recall）：本应答对的问题中，实际答对的比例

公式：召回率 = $TP / (TP + FN)$

F1 分数：综合准确率和召回率的调和平均数（“整体性能”）

公式： $F1 = 2 \times (\text{准确率} \times \text{召回率}) / (\text{准确率} + \text{召回率})$

真实类别\预测类别	预测为 “正确”	预测为 “错误”	真实总计
正类（本应答对）	27	0	27
负类（本应答错）	0	3	3
预测总计	27	3	30
核心指标	准确率=100%	召回率=100%	F1=100%

2. 数据完整性与质量

(1) 系统通过多层验证机制保障基础数据质量（核心字段提取成功率超 98%，电话号码提取率 90%+，多元融合技术优化电话数据）而智能体作为数据应用的核心，将这一基础转化为高效服务能力；

(2) 智能体成功读取以事项名称为键的 JSON 文件，在最终输出数据时，以“数据完整性”为核心呈现标准：输出内容会全面覆盖事项对应的所有核心信息维度（含事项名称、办理地点、申请材料、咨询方式、受理条件等），无关键信息维度缺失；在此基础上，“事项名称 - 关键字段”的检索映射建立准确率达 100%，输出数据能精准关联事项与对应核心内容，无任何字段错配；同时

智能体对输出字段进行规范化输出，彻底服务偏差，以完整、准确的输出结果提升用户体验。

3. 运行效率与稳定性

（1）系统高效完成数据采集（55 页约 500+事项处理时长 10-15 分钟，随机延时策略降低反爬风险），为智能体提供稳定数据供给，而智能体在服务环节展现出更优的效率与可靠性；

（2）在用户交互中，智能体平均在 3 秒内可以完成响应，响应速度较快，满足即时即答的基本需求。更关键的是，智能体回复的准确率高达 100%，在 600 条多维度咨询测试中，均能准确调取官方信息，与政务服务网内容完全一致，无信息偏差。同时智能体在查询流程响应时仍保持 3 秒内响应，无因数据断供导致的中断，完全满足政务服务“全天候、高稳定”的需求，为用户提供有效指引，并且测试过程中系统峰值内存占用远低于当前主流电脑的基础内存配置，无内存溢出或卡顿现象，即便是日常办公用电脑也能轻松承载其运行。

三、应用价值

（一）经济效益

1. 降低数据获取成本

本系统将数据获取时间从人工收集的数周缩短至 10-15 分钟，大幅降低了数据获取的人力和时间成本。以 500+事项的规模计算，人工收集至少需要 2-3 名工作人员工作 1-2 周，而自动化爬取仅需 10-15 分钟，效率提升约 1000 倍。这种效率提升直接转化为显著的经济价值，特别是在需要频繁更新数据的场景下，长期成本节约更为可观。

2. 提高政务数据利用效率

为政府部门提供现成的结构化数据，减少数据整理投入，提高决策效率。政府部门通常需要投入大量资源进行数据清洗和整理，而本系统直接提供高质量的结构化数据，可将数据准备时间减少 80%以上，使政府部门能够更专注于数据分析和应用，提升政务服务的精准性和有效性。

（二）社会效益

1. 促进政务信息公开透明

本项目将分散在济南市政务服务网各页面的非结构化信息整合为结构化数

据集，显著提高了政务信息的可获取性和可理解性。这种信息整合使公众能够更便捷地了解政务服务事项的详细信息，包括办理条件、材料要求、联系方式等，增强了政府工作的透明度，符合“阳光政务”的理念。

2. 提升政务服务可及性

通过结构化数据的提供，本项目为开发第三方政务服务应用奠定了基础，使公众获取政务服务更加便捷：

（1）多渠道获取：基于结构化数据开发的 APP、小程序等，使公众可通过多种渠道获取服务信息；

（2）精准匹配：结构化数据支持智能匹配，帮助公众快速找到适合自己的服务事项；

（3）无障碍访问：结构化数据更易于实现无障碍访问功能，服务特殊群体。

这些改进显著提升了政务服务的可及性，特别是对数字技能有限的群体，降低了获取政务服务的门槛。

综上所述，本项目不仅实现了济南市政务服务数据的自动化采集和结构化处理，更重要的是将非结构化的网页信息转换为可分析、可应用的高质量数据资源，为政务服务的优化和创新提供了坚实基础。其技术先进性与实用性的结合，使其在电子政务领域具有显著的应用价值和推广前景，既创造了直接的经济效益，也带来了广泛的社会效益，是“互联网+政务服务”理念的成功实践。

四、算法使用步骤与示例

（一）数据采集

1. 概述

数据采集使用 Python 语言编写了一个爬虫脚本，旨在高效采集济南市政务服务网的个人办事项数据。系统可精准提取事项名称、办理部门、受理条件等核心信息，并将其自动化处理为结构化的 CSV 文件，为后续的数据分析和应用提供支持。

2. 环境配置

①基础环境：

Python 3.7+

操作系统：Windows, macOS, Linux

②依赖安装：打开终端，执行以下命令即可一键安装所有必需的库

```
pip install requests pandas beautifulsoup4 cloudscraper
```

3. 数据采集流程

3.1 会话初始化与反爬绕过

①智能会话：采用 `cloudscraper.create_scraper()` 创建会话对象，该对象能自动处理目标网站的 JavaScript 反爬验证（如动态 Cookie 生成），比传统的 `requests.Session()` 更具鲁棒性。

②请求伪装：配置了模拟浏览器的 `HEADERS`（包含 `User-Agent`、`Referer` 等），使请求看起来像是普通用户的合法访问，有效降低被服务器识别为爬虫的风险。

③参数准备：首先访问初始页面（`START_URL`），此举不仅是为了获取会话 Cookie，更是为了从页面中解析出后续 API 请求所必需的隐藏参数（如 `theme`、`deptCode`）。

3.2 分页事项列表获取

①API 请求：通过分析发现，事项列表是通过一个 API 接口（`DEPT_LIST_API_URL`）动态加载的。因此，程序构造了带有特定参数（如 `areaCode`、`pageno` 等）的请求来模拟这一过程。

②循环遍历：在一个循环中，程序从第 1 页迭代至预设的最大页码 `MAX_PAGE`，逐页请求 API，获取包含事项列表的 HTML 片段。

③链接提取：利用 CSS 选择器 `a.li_bt` 从返回的 HTML 中提取每个事项的详情页链接（`href`）和事项名称（`title`）。同时，通过 `urllib.parse.urljoin` 将可能存在的相对 URL 路径拼接为完整的绝对 URL。

3.3 详情页数据精准提取

①页面获取：发送 GET 请求获取详情页的完整 HTML，并设置了 20 秒的超时时间，以防因特网问题导致程序长时间阻塞。

②精准解析：使用 `BeautifulSoup` 对页面进行解析，通过标签、类名和文本内容等多种方式精确定位并提取核心字段。

3.4 数据处理与存储

①数据聚合：在爬取过程中，每个事项的结构化数据（以字典形式存储）被添加到一个主列表 `all_scraped_data` 中。

②格式统一：采集结束后，利用 `pandas.DataFrame` 将列表高效地转换为二维数据表。同时，定义了固定的列顺序，确保每次输出的 CSV 文件格式完全一致。

③编码优化：在保存为 CSV 文件时，采用 `utf-8-sig` 编码，此举可以有效避免在 Microsoft Excel 等软件中打开时出现中文乱码的问题。

④异常处理：在网络请求和页面解析的各个环节都加入了异常捕获逻辑。当发生错误时，会返回“未找到”或“解析出错”等标记，并打印错误信息，但不会导致整个程序的崩溃，保证了系统的稳定性。

4. 数据采集指导与示例

4.1 基础运行流程

- ①准备：确保已完成环境与依赖安装；
- ②执行：直接运行源代码文件 `get_gov_data.py`；
- ③输出：程序运行结束后，将在同级目录下生成结果文件“`gov_original_data.csv`”

4.2 关键配置说明

在源代码文件开头部分，可直接修改以下全局变量以自定义爬虫行为：

配置项名称	含义与修改建议
OUTPUT_FILE	数据存储路径。可修改为绝对或相对路径，如 “ <code>D:\\data\\output.csv</code> ”。
MAX_PAGE	最大爬取页码。可适当调小以进行快速测试，或根据需求设定。
api_params	事项筛选参数。用于定义采集的数据范围。

4.3 典型使用示例

（1）快速测试（仅爬取前 3 页）

为了快速验证流程，仅采集少量数据：

将代码中的 `MAX_PAGE = 55` 修改为 `MAX_PAGE = 3`。

（2）采集所有类型事项

系统默认只采集“网办事项”，现需采集包括窗口办理在内的全部事项。

找到 `api_params` 字典，将其中的“`isonline`”：“1”修改为“`isonline`”：

“0”。

(3) 自定义输出文件路径

①需求：将数据保存到 D:\政务数据 文件夹下。

②操作：确保该文件夹已存在，然后将 OUTPUT_FILE 的值修改为 “D:\\政务数据\\gov_original_data.csv”。

5. 附件与数据字段

(1) 源代码附件：get_gov_data.py

(2) 输出数据集附件：gov_original_data.csv;

(3) 数据字段说明：

字段名称	字段含义
部门名称	事项的实施或主管单位
事项名称	政务服务事项的官方全称
咨询方式	去重、格式化后的咨询电话
办理地点	线下实体大厅或窗口的详细地址
受理条件	办理该事项所需满足的前置条件
材料名称	申请该事项需提交的材料清单

6. 注意事项

(1) 合规性：请勿将爬取延时设置得过短，以避免对目标服务器造成不必要的压力。

(2) 平台变更：如遇网站改版，可能需要同步更新代码中的解析规则。

(3) 编码问题：若在 Excel 中打开 CSV 文件出现乱码，请使用“数据”->“自文本/CSV”功能导入，并在文件源格式中选择“65001: Unicode (UTF-8)”。

(二) 数据清洗

1. 算法（脚本功能）说明

该算法使用 pandas 库，旨在对名为 gov_original_data.csv 的 CSV 文件进行一系列的数据清洗和预处理操作。其核心目标是移除无效、冗余或不需要的

数据，生成一个更干净、可用于分析的数据集。其清洗流程严格按照以下四个步骤执行：

（1）按“部门名称”筛选

操作：脚本会首先移除 部门名称 这一列中所有值为“济南市行政审批服务局”的数据行。

目的：这通常是为了排除特定部门的数据。

（2）按关键词筛选

操作：脚本会检查每一行的所有单元格，如果任何一个单元格中包含“未找到”或“未匹配”这两个关键词，整行数据都将被删除。

目的：这两个关键词通常表示数据采集或匹配过程中出现了错误或缺失，属于无效数据，需要被清理。

（3）按“业务办理项编码”去重

操作：脚本会根据 业务办理项编码 这一列的值来识别和删除重复的数据行。对于编码相同的多条记录，只保留第一次出现的那一条。

目的：业务编码通常是唯一的标识符，此步骤可以确保每项业务只有一条唯一的记录，避免数据冗余。

（4）按“事项名称”、“受理条件”和“材料名称”组合内容去重

操作：在完成编码去重后，脚本会进一步根据事项名称、受理条件和材料名称 这三列的内容组合来进行去重。只有当这三列的内容完全相同时，才被视为重复记录，并同样只保留第一条。

目的：此步骤旨在清除那些虽然业务编码不同，但核心内容（事项、条件、材料）完全相同的重复数据。

脚本在执行完毕后，会将清洗后的数据保存到一个新的 CSV 文件 `济南政务gov_cleaned_data.csv` 中，并在控制台打印出详细的报告，包括原始数据总行数、每一步清洗后剩余的行数以及总共筛选掉的行数，让你能清晰地了解数据清洗的效果。

2. 使用说明

要运行这个脚本，你需要有 Python 环境，并按照以下步骤操作。

（1）准备工作

①安装 Python: 如果你的电脑上没有安装 Python, 请从 Python 官网 下载并安装。

②安装 pandas 库: 脚本依赖于 pandas 库。打开你的终端或命令提示符, 输入以下命令进行安装:

③`pip install pandas`

(2) 文件放置

将 `clean_gov_data.py` 脚本文件和需要被清洗的数据源文件 `gov_original_data.csv` 放置在同一个文件夹(目录)下。这是最重要的一步, 否则脚本会因为找不到文件而报错。

(3) 运行脚本

①打开终端或命令提示符。

②使用 `cd` 命令切换到你存放上述两个文件的文件夹路径。例如:

```
cd /Users/yourname/Documents/DataCleaning
```

③输入以下命令来运行脚本:

```
python clean_gov_data.py
```

(4) 查看结果

控制台输出: 脚本运行后, 你会在终端或命令提示符窗口看到类似下面的输出信息, 它展示了整个清洗过程的统计数据:

```
文件读取成功, 开始处理...

-----
处理完成!
原始数据总行数: [原始数量]
- 移除 [济南市行政审批服务局] 后剩余: [数量]
- 移除 [关键词] 后剩余: [数量]
- 移除 [重复编码] 后剩余: [数量]
- 移除 [重复内容] 后最终剩余: [最终数量]

-----
总计筛选掉数据行数: [被移除的数量]
筛选后的数据已保存为 '济南政务数据清洗后.csv'
-----
```


生成文件: 在同一个文件夹下, 你会找到一个名为 `gov_cleaned_data.csv` 的新文件, 这就是经过所有清洗步骤后得到的干净数据。你可以用 Excel 或任何文本编辑器打开它进行查看。

(三) 智能体问答系统搭建

1. 工作原理

该算法是一套基于大模型的信息处理与交互流程，核心是围绕用户输入，依次进行关键字提取、知识库检索、内容规范化等操作，最终生成符合要求的输出结果。具体流程为：

- （1）输入接收：首先获取用户输入内容。
- （2）关键字提取：利用指定的大模型对用户输入提取关键字，为后续的知识库检索或直接回答提供关键信息支撑。
- （3）关键字有无判断：判断提取到的关键字情况，若有有效关键字，进入知识库检索环节；若没有或不满足一定条件，进入直接返回关键词不存在时提示语。
- （4）知识库检索：当存在有效关键字时，依据关键字在知识库中检索相关信息，为生成准确回答提供知识依据。
- （5）内容输出判断与规范化：根据知识库检索结果，借助大模型能力对内容进行规范化处理，确保输出格式、表述等符合要求。
- （6）结果返回：将最终处理好的内容输出，以规定格式返回给用户。如下图所示：



2. 使用方法

- （1）安装前提：使用 Coze 资源库中的知识库，须提前将表格导入知识库中。
- （2）运行步骤：
 - ①准备输入：用户输入文本形式的问题、需求等；
 - ②启动流程：触发算法流程，算法会自动按照 “输入接收→关键字提取→关键字有无判断→知识库检索→内容输出判断与规范化→结果返回” 的顺序执行；
 - ③获取输出：流程执行完毕后，获取最终规范化数据结果。

3. 可能的配置选项

模型相关配置：模型选择：配置使用的大模型，选择豆包大模型：豆包·1.0·Pro·16k

技能与流程节点配置：

①技能添加与配置配置技能模块，关键字提取、知识库检索、内容规范化技能外对于已有技能，可配置其具体参数：

“提取关键字”技能可设置提取关键字为“动作”+“对象”，关键字数量上限为3，长度小于15；

“知识库检索”技能可配置检索的知识库源为coze知识库、检索的匹配度阈值为0.7。

②流程节点参数：对流程中的“节点关键字有无”判断节点、“输出”节点进行参数设置：

流程节点参数：对流程中的“节点关键字有无”判断节点、“输出”节点进行参数设置：

“输出”节点配置输出文本的格式模板，输出完整的关键字段。

数据存储路径：

知识库路径：将本地数据上传至coze资源库的知识库下，确保算法能准确访问到知识库内容进行检索操作。

4. 使用示例

问题查询与响应结果

①用电过户流程有哪些步骤？电话是啥？响应结果如下：

 wr001


用电过户流程有哪些步骤？电话是啥？

 终济南政务


好的亲，我将根据您的输入的问题来为您回答：

事项名称：用电过户
办理地点：山东省济南市市中区站前路9号济南市政务服务中心4楼民生监管专区综合受理窗口F12
办理时间：工作日星期一至星期五，上午09:00-12:00，下午13:00-17:00（法定节假日除外）
受理条件：供电公司辖区内的直供用户
咨询方式（联系人 / 联系电话）：0531-89027469
是否收费：否
是否网办：是
材料名称（办事需要的条件 / 流程）：不动产权证书；营业执照；身份证；经办人有效身份证明；授权委托书
区划名称：济南市

②前一段时间住院了，住院费用报销可以咨询哪个电话？响应结果如下：




③我租了一个房屋，要去哪里备案？响应结果如下：



操作流程

①“用电过户办理”流程智能问答流程：



输入接收：用户输入关于“用电过户”的问题，此为流程的起始输入。

关键字提取：利用豆包·1.5·Pro·32k 模型，从用户输入中提取关键字 “用电过户”，为后续检索提供关键信息。


关键字有效性判断：判断提取的关键字 “用电过户” 是否有效，若有效则进入下一步；若无效则输出提示词。

知识库检索：以 “用电过户” 为查询关键字，在 “终济南” 知识库中检索相关信息，获取包含办理地点、时间、条件、材料等内容の結果列表。

内容规范化输出：将知识库检索到的结果，通过豆包·1.5·Pro·32k 模型进行规范化处理，整理成清晰、有条理的文本，明确列出事项名称、办理地点、时间等各项信息。

结果返回：把规范化后的文本返回给用户，完成整个问答流程，让用户得到关于用电过户办理的详细解答。

② “住院费用报销” 咨询智能问答流程：



输入接收：用户输入关于住院费用报销咨询的问题，作为流程的初始输入。

关键字提取：利用豆包·1.5·Pro·32k 模型，从用户输入中提取关键字 “住院费用报销咨询”，为后续的知识库检索提供关键信息。

关键字有效性判断：判断提取的关键字 “住院费用报销咨询” 是否有效，若有效则进入下一步；若无效则输出提示词。


知识库检索：以 “住院费用报销咨询” 为查询关键字，在 “终济南” 知识库中检索相关信息，获取包含办理地点、时间、咨询电话等内容の結果列表。

内容规范化输出：将从知识库检索到的结果，通过豆包·1.5·Pro·32k 模型进行规范化处理，整理成清晰、有条理的文本，明确列出事项名称、办理地点、办理时间、咨询电话等各项信息。

结果返回：把规范化后的文本返回给用户，完成整个问答流程，让用户得到

关于住院费用报销咨询的详细解答。

③ “房屋租赁备案办”理智能问答流程：



输入接收：用户输入关于房屋租赁备案的问题，作为流程的初始输入。

关键字提取：借助豆包·1.5·Pro·32k 模型，从用户输入中提取关键字 “房屋租赁备案”，为后续的知识库检索提供关键依据。

关键字有效性判断：判断提取的关键字 “房屋租赁备案” 是否有效，若有效则进入下一步；若无效则输出提示词。

知识库检索：以 “房屋租赁备案” 为查询关键字，在 “终济南” 知识库中检索相关信息，获取包含办理地点、时间、条件、咨询方式等内容の結果列表。

内容规范化输出：将从知识库检索到的结果，通过豆包·1.5·Pro·32k 模型进行规范化处理，整理成清晰、条理分明的文本，明确列出事项名称、办理地点、办理时间等各项信息。

结果返回：把规范化后的文本返回给用户，完成整个问答流程，使用户得到关于房屋租赁备案办理的详细解答。