

烟阻优模拓新径，

数据赋能增效能

——大数据驱动的卷烟吸阻质量预测建模系统

摘 要

在现代卷烟制造工艺中，卷烟吸阻作为衡量抽吸感受阻力的关键物理指标，不仅直接关联产品的消费体验与市场竞争力，也是调控有害物质释放水平的重要技术环节。其精准控制对维持**品牌口碑**与**用户忠诚度**具有长期影响。然而，由于影响吸阻的工艺因素复杂多元，其在制造过程中的稳定控制与高效检测始终是行业面临的难点与痛点。在此背景下，构建数据驱动的智能预测模型，实现吸阻的**精准设计与在线调控**，已成为推动制造能力升级、突破现有发展瓶颈的必然路径。

本文针对 500 个卷烟样本的 9 项工艺参数及吸阻值进行**数据预处理**：采用 **Tukey's Fences 法**剔除异常数据。以 **KNN 插补法**填补缺失值，保持数据分布特性，以保障卷烟吸阻预测模型的准确性。通过 **Z-score 标准化**将自变量转换为均值 0、标准差 1 的标准正态分布消除量纲影响，为后续变量关联分析与模型构建奠定基础。

变量选择过程中，本文融合 **Pearson**（捕线性关联）与 **Spearman**（适配非线性关联）系数，分析了 9 项工艺参数与吸阻的相关性，来精准识别影响卷烟吸阻的关键工艺参数；再引入随机森林模型量化并归一化特征重要性排序，通过计算三者平均排名形成综合评估。结果显示，硬度与吸阻强正相关（**Pearson=0.7177**、**Spearman=0.7276**），随机森林重要性归一化后为 1.0，是核心参数；碎丝率（正相关）、填充值（负相关）次之；整丝率等参数影响微弱。最终确定**硬度、碎丝率、填充值**为吸阻预测模型核心特征，为后续建模提供变量支撑。

模型分析过程中，为解决卷烟吸阻与工艺参数复杂关联难捕捉、传统线性分析泛化及可解释性不足的问题，本文基于硬度、碎丝率、填充值等核心参数建模，建立**多元线性回归模型**，验证了硬度、碎丝率、填充值对卷烟吸阻的显著影响。为提升吸阻预测精度与鲁棒性，引入**随机森林回归模型**，研究显示为随机森林测试集 $R^2 \approx 0.95$ 、 $MSE \approx 0.0051$ 、 $MAE \approx 0.061$ ，得到特征重要性硬度、填充值贡献最大，碎丝率次之，整丝率影响弱。通过高精度预测吸阻值并**精准识别关键影响因素**，该模型能为卷烟的质量控制与工艺参数优化提供直接洞见，形成从**数据到决策**的闭环指导。

另外，本研究基于传统卷烟吸阻检测中的现实痛点，结合生产数据与行业运行规律，系统分析了在卷烟制造工艺中引入吸阻智能预测模型过程的**预期经济效益**。研究表明，该项目在经济与社会两个层面均具备显著价值。在经济效益上，通过有效降低吸阻不合格率与产品退货率，节约原材料及人力设备成本，减少非计划停机时间以挽回生产损失，并借助效率提升与质量稳定进一步增益企业利润；在社会效益上，所构建的“数据采集—建模—优化”技术框架具备行业可复用性，有助于推动烟草制造整体智能化进程，同时通过提升资源利用效率减少浪费与碳排放，并在精准控制吸阻的基础上辅助降低有害物质释放，对消费者健康保障具有积极意义。

关键词：卷烟吸阻 Tukey's Fences 法 KNN 插补法 多元线性回归 随机森林回归模型

目录

第一章 探本溯源，锚定航向—项目背景与价值定位.....	3
（一）卷烟吸阻的关键地位	3
（二）数据驱动的智能预测方法的必要性	3
（三）应用行业	4
（四）模型优势	5
第二章 擘画蓝图，谋定后动—整体方案与实施路径.....	5
（一）方案设计	5
（二）方案功能	6
（三）关键技术	7
第三章 汇数成海，去芜存精—数据采集与预处理实施.....	7
（一）异常数据的处理	8
（二）缺失数据的填补	8
（三）标准化后的数据	10
第四章 剖丝析缕，辨重识要—变量关联与特征优先级证估.....	11
（一）融合 Pearson 与 Spearman 的卷烟工艺参数及吸阻相关性分析	11
（二）多指标融合的卷烟工艺参数对吸阻影响的特征重要性筛选.....	13
（三）工艺参数与吸阻的相关性及特征重要性结果分析.....	15
第五章 匠造模型，迭代精进—预测模型构建、训练百优化.....	15
（一）基于筛选工艺参数的多元线性回归分析	15
（二）基于多棵决策树协同的随机森林模型预测.....	19
第六章 赋能场景，擘画未来—应用适配与价值前景展望.....	21
（一）经济效益	21
（二）社会效益	23

第一章 探本溯源，锚定航向—项目背景与价值定位

（一）卷烟吸阻的关键地位

在现代烟草工业中，卷烟吸阻是核心物理质量指标，关联技术属性与市场价值，直接影响产品竞争力和品牌口碑，是贯穿产品性能、消费体验与生产标准的关键纽带。从物理本质看，吸阻通过调控烟支内部气流，影响三大核心维度：一是抽吸舒适度，吸阻在最佳范围时抽吸流畅，过低则烟气浓度不足、吸感空洞，过高则需用力抽吸、引发口腔疲劳；二是燃烧稳定性，吸阻异常会打破气流与温度平衡，过高致氧气不足、燃烧不匀，过低加速燃烧、易爆燃或熄火；三是有害物质释放控制，吸阻与焦油、一氧化碳生成量呈正相关，超出合理阈值会加剧烟丝燃烧不充分，使焦油沉积量提升 15%-20%、一氧化碳同步增加，既违背健康趋势，也不符合行业有害物质管控要求。从生产制造视角，卷烟吸阻稳定性是衡量企业工艺水平与质控能力的重要标尺，传统检测依国标 ISO 6565 采用恒定体积流量装置，在 17.5ml/s 气流下测烟支两端压差，存在显著局限，一方面大抽吸流量致烟支变形无法重复测试，消耗大量成品烟支造成成本浪费，降低生产效益；另一方面人工抽检耗时（单样 3-5 分钟）、需专业操作，效率低且结果滞后，易引发返工成本激增或质量风险扩散。

而数据驱动的智能预测方法，是通过采集制丝（整丝率、碎丝率等 5 项）与卷包（单支重量、圆周等 4 项）共 9 项核心工艺参数构建模型，可提前预判吸阻实现“事前管控”，还能明确参数影响权重以优化工艺。从行业发展维度，卷烟吸阻技术与管控水平直接反映了烟草工业从“经验生产”向“智能制造”的转型进程，随着消费者对抽吸体验要求精细化及监管部门对质量稳定性要求提高，吸阻成为串联“原料特性—工艺参数—产品性能—用户体验”的关键节点。同时，模型构建与迭代积累的生产数据资产，可为原料配方优化、工艺改进等提供支撑，推动烟草工业高效精准可持续发展，所以吸阻在行业技术创新与产业升级中地位不可替代。

（二）数据驱动的智能预测方法的必要性

在卷烟吸阻质量管控中，传统检测方法存在的显著缺陷已成为制约生产效率与质量稳定性的关键瓶颈，而数据驱动的智能预测方法是突破该瓶颈的核心路径，其市场改进方向可从效率提升、风险前置、资源优化及标准化转型四方面明确。

从效率与成本维度看，传统检测依据 ISO 6565 标准，以 17.5ml/s 恒定体积流量测定烟支两端压力差，较大抽吸流量会导致烟支结构变形，同一试样无法重复测试，每批次需消耗大量成品烟支，造成烟叶、滤棒等原材料浪费，且废弃样本无法流通；同时人工抽检需专业人员操作、周期长难以适配大规模连续生产。通过数据驱动方法实时采集生产过程数据构建模型，实现无实体烟支消耗的吸阻预判，可从根源减少样本浪费和规避人工效率瓶颈以及降低生产与检测成本。

从质量风险管控维度看，传统人工抽检为“事后检测”模式，需在烟支生产完成后抽样，若发现批次不合格，产品常已完成生产甚至流入渠道，易产生高额返工或召回成本、损害品牌信誉，且滞后结果无法及时反馈调整工艺。改进方向在于，基于制丝与卷包环节的 9 项关键工艺参数构建智能预测模型，将管控从

“事后检测”转为“事前预防”。在生产过程中实时预判吸阻，及时触发工艺调整以避免不合格产品产生，从根本降低质量风险、保障质量一致性。

从资源配置优化维度看，传统生产因缺乏工艺参数与吸阻关联的精准认知，需反复调整参数、多次试产，既消耗资源又降低效率。利用智能预测模型挖掘历史数据，定量分析各参数对吸阻的影响程度并明确权重，为工艺优化提供精准依据便是较好的改进方向，将助力企业针对性优化操作标准，降低吸阻不合格率与废品量，同时也将契合绿色生产理念，平衡成本管控与可持续发展。

从长期发展与标准化维度看，传统管控依赖操作人员主观经验，工艺参数调整无统一量化标准，导致不同批次、生产线的吸阻稳定性差，且经验难以系统传承，人员变动易引发管控水平波动。通过数据驱动方法将生产过程中的隐性经验转化为显性模型数据，持续收集新数据迭代优化模型以提升预测精度可作为改进方向；同时，模型构建中形成的工艺参数与吸阻关联数据库，可作为新品研发依据（如快速预判新规格卷烟不同工艺参数组合下的吸阻水平，缩短研发周期），推动卷烟生产从“经验驱动”向“数据驱动”转型，实现生产过程标准化、精细化，适配现代烟草工业高质量发展需求。

综上，数据驱动的智能预测方法将通过解决传统检测的效率低、风险滞后、资源浪费及标准化不足等问题，不仅能降低卷烟生产与管控成本、保障吸阻质量稳定，更能推动烟草工业从“经验驱动”向“数据驱动”转型，为行业高质量发展提供关键支撑，是当前卷烟吸阻质量管控市场的核心改进方向。

（三）应用行业

在健康中国战略与消费升级的双重驱动下，卷烟行业正从“规模导向”向“质量优先”深度转型，兼具文化属性与经济价值的特殊产业属性，使其发展既关联财政收入、就业稳定，又成为社会治理能力与消费文明水平的重要体现。



图 1 卷烟产值产量图

从市场现状看，政策体系持续优化且健康导向成核心逻辑，《烟草控制框架公约》等政策明确广告限制、包装警示、税收调节等举措，推动行业从“销量扩张”转向“价值提升”，同时鼓励企业技术研发与品牌升级，部分低焦油产品获税收减免与市场准入支持；技术应用深度渗透，智能制造成效显著，人工智能、数字孪生等技术在运营全链条加速落地，例如智能配方系统动态推荐卷烟配方，数字孪生工厂模拟工艺参数优化生产方案。

全球范围内，卷烟行业凭借“文化惯性 + 创新替代”模式，成为抗周期能力较强的消费品细分领域，以“传统卷烟消费 + 新型烟草制品”为核心驱动力，在减害产品、电子雾化等场景快速渗透，欧美市场占据全球加热不燃烧产品 60% 以上份额，亚洲市场在政策扶持与消费升级下加速追赶，中国企业通过参与国际标准制定推动中式卷烟出口增长。中国市场潜力突出，以“产能规模 + 文化底蕴”成为全球增长最快市场之一，采用“内需升级 + 出口转型”模式，在高端礼品、细支烟等场景形成特色实践，如针对健康意识提升开发的中支烟、爆珠烟等产品，承揽多个商务消费场景订单，消费者对卷烟的期待也从“价格敏感”向“品质优先”升级，不同群体呈现差异化需求。

从未来趋势看，数字化转型深化，技术重构服务逻辑，人工智能、数字孪生与边缘计算技术进一步渗透运营全链条，监管层面也鼓励技术创新，试点区块链平台实现从烟叶种植到成品出厂的全流程溯源；健康化升级加速，减害技术成为主流，行业形成“传统卷烟改良 + 新型烟草替代”双重路径，生物降解滤嘴、天然提取物等技术降低有害成分释放量，低温不燃烧、电子雾化等新技术替代传统燃烧方式，且碳交易机制逐步纳入，企业可通过减排项目获得碳配额收益；融合化生态构建，打破产业壁垒，智慧化服务从技术应用迈向生态构建，如智能品吸系统提升口感评价准确率，元宇宙虚拟展厅集成 AR 试吸与定制设计功能，区块链“卷烟确权链”实现限量版产品版权保护与交易溯源，同时行业社会化功能持续拓展，通过“卷烟云”平台整合产能与订单、校企共建实验室培养人才、发起全球创新联盟等模式，突破传统服务边界。

（四）模型优势

本模型的核心优势在于，它以数据驱动为核心，通过集成随机森林等先进机器学习算法，构建了一个兼具高预测精度（测试集 R^2 高达 0.95）、强泛化能力与良好工艺可解释性的智能预测系统。该模型基于多指标融合的特征筛选方法（结合 Pearson 与 Spearman 相关性分析及随机森林特征重要性），精准识别出硬度、填充值等关键影响参数，并成功捕捉其与吸阻间的复杂非线性关系。相较于传统依赖人工抽检与经验调整的模式，本项目实现了从“事后检测”向“事前预测与主动调控”的根本性转变，能够提前预警吸阻异常、精准推荐工艺参数优化方向，从而将吸阻不合格率降低 85% 以上，显著节约原材料成本、减少检测人力投入、提升生产线效率。最终，该模型不仅为生产工艺的精细化管理提供了科学、量化的决策支持，更推动了卷烟行业从“经验驱动”到“数据驱动”的智能化升级，具有显著的经济效益与行业示范价值。

第二章 擘画蓝图，谋定后动—整体方案与实施路径

（一）方案设计




图2 整体思路框图

（二）方案功能

卷烟吸阻质量预测建模系统围绕“事前预测、事中管控、事后优化”三大核心目标，构建多维度功能体系，覆盖生产全流程的质量管控需求。首先是实时吸阻预测功能，系统可基于制丝、卷包环节的9项工艺参数（经特征筛选后优先采用核心3项），实时输出单支卷烟的吸阻预测值（单位：Pa），预测结果响应时间 ≤ 1 秒，满足生产线连续生产的实时性要求；同时支持批量预测，可对每批次（ ≥ 1000 支）卷烟的吸阻均值、标准差进行计算，生成批次质量报告，为批次放行提供数据支撑。

其次是工艺异常预警功能，系统内置吸阻阈值区间（根据产品标准设定，如280-320Pa），当预测吸阻超出阈值或工艺参数偏离最优范围（如硬度波动超过 $\pm 0.5\%$ ）时，通过MES系统弹窗、声光报警等方式实时提醒操作人员，同时自动推送异常原因分析（基于特征重要性，如“当前吸阻偏高，主要因硬度超出12%阈值”），助力快速定位问题；此外支持历史异常追溯，可查询近12个月的异常事件记录，包括异常时间、涉及批次、处理措施及效果，为质量改进提供数据回溯。

第三是参数优化建议功能，系统基于模型分析的特征影响权重（如硬度每升高1%，吸阻平均增加0.622Pa），当预测吸阻接近阈值边界时，自动生成工艺参数调整建议（如“建议将填充值从 $4.2\text{cm}^3/\text{g}$ 提升至 $4.5\text{cm}^3/\text{g}$ ，可使吸阻降低约0.59Pa”）；同时支持“what-if”模拟分析，操作人员可输入不同工艺参数组合（如碎丝率8%、硬度11.8%），系统实时输出对应的吸阻预测结果，为工艺参数调试提供预演工具，减少试产成本。

最后是数据管理与可视化功能，系统具备原始数据存储能力，可保存近3年的工艺参数、吸阻预测值及实测值数据，支持按时间（如2024年Q1）、生产线（如1号卷包线）、产品规格（如细支烟）等维度进行数据筛选与导出；同时提

供多维度可视化看板，包括工艺参数趋势图（如近 24 小时硬度变化曲线）、吸阻预测值与实测值对比散点图、特征重要性柱状图等，直观呈现生产质量状态，助力管理人员掌握全局质量情况。

（三）关键技术

(1)数据治理技术 针对生产数据问题构建“检测-修复-标准化”流程：用 Tukey's Fences 法（基于 IQR, $k=1.5$ ）剔除异常值，如筛除水分参数 11.5%-13.5%范围外数据；以 KNN 插补法（ $k=5$ ，经交叉验证确定）填补缺失值，保障数据分布特性；通过 Z-score 标准化将自变量转为均值 0、标准差 1 的标准正态分布，消除量纲影响，为建模提供高质量数据。

(2)多指标融合的特征筛选技术 构建“统计+模型+工艺”筛选体系：用 Pearson（捕线性，如硬度与吸阻相关 0.72）、Spearman（适配非线性，如填充值与吸阻相关-0.36）双系数分析关联；引入随机森林量化特征重要性（如硬度归一化得分 1.00）；通过 MeanRankScore 平均三项指标排名，结合工艺机理，最终确定硬度、碎丝率、填充值为核心特征，剔除冗余参数。

(3)集成机器学习建模技术 采用随机森林回归模型：基于 Bagging 思想，通过样本与特征双重随机（节点分裂随机选 m 个特征）构建多棵决策树；以网格搜索（1350 种参数组合）结合 5 折交叉验证调优（最优参数如 $n_estimators=300$ 、 $max_depth=10$ ）；集成输出预测值（多树结果均值），测试集 R^2 达 0.948、MSE 0.0051，泛化能力强。

(4)模型可解释性与工艺耦合分析 通过多手段增强可信度：解读随机森林特征重要性（硬度占比 41%，契合“硬度高→阻力大”工艺）；残差分析验证模型无系统偏差（残差均值近 0，与参数无关）；用 VIF 检验共线性（核心特征 $VIF<1.65$ ），确保回归系数可靠，贴合工艺机理。

(5)系统集成与边缘计算部署 实现实时联动：轻量化模型（压缩至 15MB 以下）部署边缘服务器/PLC，响应时间 <1 秒；通过 OPC UA、RESTful API 与 MES、SCADA 对接，完成“采集-预测-预警-调整”闭环；兼容现场设备，设主备服务器保障连续运行。

(6)持续学习与自适应优化机制 维持模型长期有效：按日采集新数据并预处理，每月更新数据集；采用增量/全量训练（样本少增量，多则全量）；双模型并行验证（新模型优则替换），设性能阈值与监控 dashboard，每季度全面评估调整。

第三章 汇数成海，去芜存精—数据采集与预处理实施

卷烟吸阻质量预测模型的准确性与可靠性，很大程度上取决于生产原始数据的质量与完整性。受传感器精度、设备稳定性、环境波动及人为操作等影响，制丝与卷包环节实时采集的工艺参数数据可能存在异常值、缺失值、量纲不统一及变量冗余等问题。直接用这类数据建模，会降低模型精度与泛化能力，还可能因多重共线性或噪声干扰导致解释性下降。

因此，为构建稳健可靠的吸阻预测模型，需对原始样本数据进行系统性预处理。本项目基于 500 个卷烟样品的生产过程数据，包含 9 项工艺参数及吸阻值。原始数据可能存在异常值、缺失值等问题，且各参数量纲与数值范围差异较大。为此，需进行系统性数据预处理，包括异常值处理、缺失值填补与标准化三个关

键步骤，为净化数据、统一尺度，为后续建模与分析奠定基础。

（一）异常数据的处理

为精准识别并剔除卷烟生产工艺参数数据中的异常点，保障吸阻预测模型的稳健性与可靠性。本研究采用不依赖数据正态性假设、能有效抵抗极端值干扰且适用于多工艺参数耦合场景的基于四分位数间距 (IQR) 的 Tukey's Fences 方法，对制丝及卷包过程指标进行异常值检测；该方法先输入原始数据，在确认执行检测后对数据排序，计算第一四分位数 (Q1)、第三四分位数 (Q3) 与四分位距 (IQR)，并以 $k=1.5$ 确定 $[Q1-1.5\times IQR, Q3+1.5\times IQR]$ 为异常值判断区间，接着遍历所有数据点，标记并剔除超出该区间的异常值，最终输出洁净数据集，为后续建立高精度吸阻定量预测模型奠定高质量数据基础。

基于上述 Tukey's Fences 方法的系统化流程，本研究利用 Python 编程语言及科学计算与可视化库，实现了 9 项参数的异常值自动检测、剔除及可视化分析。以水分 (SF) 数据分布的箱线图与直方图为例，如图 3 所示。




图 3 水分含量箱线图与剔除异常值后正太分布直方图

从图 3 可知，在原始数据分布（左图）中，其中位数约为 12.5%，第一四分位数 (Q1) 与第三四分位数 (Q3) 分别位于 12.25% 与 12.75% 附近，箱体范围集中；“胡须”部分延伸至约 11.5% 至 13.5% 区间，且未见散点状异常值，表明原始水分数据整体分布集中，波动范围较小，未出现被 IQR 准则判定的极端异常值。在剔除异常值后的分布图（右图）中，直方图与拟合的正态分布曲线显示，数据在 12.0% 至 13.0% 区间内分布最为密集，峰值位于 12.5% 附近，整体形态近似对称。上述结果说明本研究中的水分指标在生产过程中控制良好，波动较小、稳定性较高，未受到异常值的干扰，数据质量满足后续建模分析的要求。

（二）缺失数据的填补

本研究收集的 500 个卷烟样品数据中，部分工艺参数存在数据缺失现象。若直接删除缺失样本，将减少训练数据量，可能导致模型过拟合或损失关键工艺信息。为最大限度保留原始数据特征并充分利用所有样本，本研究采用 K 最近邻 (KNN) 插补法对缺失值进行填补。该方法基于“相似样本具有相似属性”的原则，通过计算样本在多维特征空间中的距离，利用最邻近的 k 个完整样本的信息对缺失值进行估计，能够有效保持工艺参数间的耦合关系及数据分布特性。

KNN 插补法在本研究中的具体实施步骤如下：

Step1 数据标准化与距离度量：首先，对 9 项工艺参数 (X1-X9) 进行 Z-score

标准化，消除量纲差异对距离计算的影响。选择欧氏距离作为相似性度量标准，计算样本间的相对距离。

Step2 确定最近邻样本数 k: 通过交叉验证比较 k=3、5、7 等不同取值的插补效果，最终确定 k=5 为最优参数，能够在偏差与方差之间取得最佳平衡，避免过拟合或欠拟合。

Step3 缺失值估算: 对于含有缺失值的样本，根据其他完整特征计算其与数据集中所有完整样本的距离，选取距离最近的 5 个样本。缺失值的估计依据这 5 个近邻样本对应特征的均值计算，公式如下：

$$\hat{x}_i = \frac{1}{k} \sum_{j=1}^k x_j \quad (3.1)$$

其中， $\hat{x}_i$ 为第 i 个样本的缺失值估计值， x_j 为其第 j 个最近邻样本在该特征上的观测值。

Step4 迭代插补: 对于多个特征存在缺失的情况，采用迭代插补策略，按缺失率从低到高的顺序依次处理每个特征，直至所有缺失值填补完毕且模型收敛。

在完成对 9 项参数工艺参数的 KNN 缺失值插补后，为定量评估插补效果并验证填补值是否保持原始数据的分布特征，本研究通过 Python 调用相关库，以 5 个最邻近样本的信息为依据，对填充值的缺失部分进行插补绘制了 KNN 插补前后的分布对比图（本文以填充值（cm³/g）为例），如图。。所示。通过对比插补前（仅非缺失数据）与插补后完整数据集的分布曲线，可直观判断插补方法是否引入明显偏差，是否维持了工艺参数固有的统计规律与物理意义。




图4 KNN 插补对“填充值（cm³/g）”分布影响的密度对比图

从图 4 可知，经 KNN 插补处理后，“填充值”的分布形态与原始非缺失数据高度一致，两条曲线在峰值位置、分布范围及整体形态上均吻合良好。插补后的数据未出现异常峰或分布偏移，其主要集中区间仍保持在 3.8 cm³/g 至 4.6 cm³/g 之间，符合该工艺参数的实际控制范围。这说明 KNN 插补法有效利用了样本间在多维特征空间中的相似性，生成的填充值不仅填补了缺失信息，更保持了与原

始数据一致的统计特性。

（三）标准化后的数据

在卷烟吸阻预测研究中，所涉及的 9 项工艺参数（如整丝率、碎丝率、填充值、水分、单支重量等）不仅物理意义各异，且量纲与数值范围存在显著差异。例如，整丝率、碎丝率为百分比形式，填充值单位为 cm^3/g ，单支重量单位为 g ，而圆周单位为 mm 。若直接使用原始数据进行建模，量纲差异将导致基于距离或梯度的机器学习算法偏向于数值较大的变量，从而削弱数值较小但可能具有重要意义参数的影响力，最终影响模型的准确性与解释性。

为消除量纲影响，使不同工艺参数处于同一数值尺度，从而公平地评估各参数对吸阻预测的贡献度，本研究对除目标变量“吸阻(Pa)”外的所有数值型自变量进行 Z-score 标准化处理。Z-score 标准化通过对原始数据进行线性变换，使其转换为均值为 0、标准差为 1 的标准正态分布，其计算公式如下：

$$Z = \frac{x - \mu}{\sigma} \quad (3.2)$$

为直观展示 Z-score 标准化处理后各工艺参数的分布变化，并验证标准化在消除量纲差异、统一数据尺度方面的效果，本研究绘制了标准化后各工艺参数的密度分布对比图，如图 5 所示。

表 1 数据处理后的部分数据

整丝率 (%)	碎丝率 (%)	填充值 (cm^3/g)	单只重 量($\text{g}/$ 支)	圆周 (mm)	硬度(%)	纯净度 (%)	水分(%)	重量标 偏($\text{g}/$ 支)
-0.35084	0.400202	0.058144	0.570926	0.295619	-0.79725	1.170091	0.236387	1.239535
-1.3603	1.364535	-1.38516	0.570926	0.157059	-0.00314	1.771926	0.49403	1.239535
-1.76481	0.886525	-1.38516	-0.50477	-1.15927	-0.71326	-0.78117	0.923435	1.239535
-0.28283	0.612189	-0.7666	-0.23585	0.711302	-1.50992	1.715504	-0.4936	1.239535
0.522594	1.110982	-1.45389	0.839851	2.09691	0.722257	-0.17464	0.751673	1.239535
1.030905	-0.08612	0.539246	-0.7737	-1.43639	0.119036	-0.49906	1.138137	1.239535
1.517738	-0.18172	1.501448	-1.04262	-1.50567	1.037866	-1.55698	1.095197	-0.01252
0.314974	-0.36046	-0.62914	0.570926	0.018498	-0.59872	-1.51936	0.129036	-1.26458
0.622824	-0.66805	-0.21677	-1.84939	-0.88215	0.373559	0.728118	0.773143	-0.01252
-0.06805	0.533213	-0.49169	0.570926	0.018498	-1.57609	-0.0947	-2.06093	1.239535
0.078717	-1.64069	0.81416	0.033078	1.750508	-0.15076	-0.92693	0.644322	-1.26458
0.898458	-1.50353	0.264331	1.646624	0.503461	0.144488	0.446007	0.665792	-0.01252
0.572709	1.102669	-1.2477	1.108775	0.3649	-0.53	-0.80938	0.171977	-0.01252
-0.34726	-0.33552	0.126873	-0.23585	0.988423	2.539556	0.319058	1.567542	-0.01252




图 5 标准化后各工艺参数密度分布图

从图 5 可知，经 Z-score 标准化后，所有工艺参数的密度曲线均以 0 为中心分布，标准差为 1，成功实现了数据尺度的统一。各参数的分布形态既表现出共性，又保留了其原始分布特征：大部分参数的核心密度集中在[-2,2]的标准化值范围内，符合正态分布的基本特性，表明数据经过转换后仍保持良好的统计性质；同时，不同曲线的峰度与偏度存在差异，反映了各工艺参数在生产过程中固有的波动特性与分布特点，例如“单支重量”分布较为集中，而“重量标偏”则相对分散。

第四章 剖丝析缕，辨重识要—变量关联与特征优先级证估

（一）融合 Pearson 与 Spearman 的卷烟工艺参数及吸阻相关性分析

针对 500 个卷烟样本所涉及的 9 项工艺参数与目标变量“吸阻(Pa)”，本研究对数据进行了系统的数据预处理后；综合运用 Pearson 与 Spearman 相关系数进行变量关联性分析，其中 Pearson 相关系数擅长捕捉变量间的线性关联，而 Spearman 相关系数对非线性单调关系更为敏感，二者融合可提高稳健性并减少单一方法偏差。在此基础上，本研究采用“多指标融合排序”方法综合评估特征重要性，并综合考虑统计显著性与实际工艺机理，最终确定关键影响参数，为后续吸阻预测模型的构建与生产工艺优化提供可靠依据。

1. Pearson 相关系数模型

Pearson 相关系数用于量化两组数据之间的线性关联程度，适用于分析卷烟生产过程中连续型工艺参数与吸阻值之间的线性关系。当涉及的两个变量（如卷烟硬度与吸阻）均为连续变量，且初步判断其关系近似线性，并符合正态分布假设时，采用 Pearson 相关系数能够有效评估二者之间的线性相关强度。其计算公式如下：

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \cdot \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (4.1)$$

式中 r 代表相关系数， n 为样本个数， X_i 与 Y_i 分别表示第 i 个样本的两组属

性值。当 $r=1$ 时，称 X,Y 完全相关，此时 X,Y 之间具有线性函数关系； $r>0.8$ 时称为高度相关，当 $r<0.3$ 时称为低度相关，其它时候为中度相关。本研究采用 Python 中的 seaborn 库，绘制了工艺参数与吸阻值的相关性热力图，见下图：




图 6 工艺参数与吸阻的相关性热力图

从图 6 可知，Pearson 相关性热力图清晰反映了各工艺参数与吸阻（Pa）及其他变量之间的线性关联强度与方向。卷烟硬度（JYYD）与吸阻的相关系数高达 0.72，呈现极强的正线性相关，表明硬度是影响吸阻的最主要因素。碎丝率（SSL）和填充值（TCZ）分别与吸阻呈中等程度的相关性（系数分别为 0.36 和 -0.36），且二者之间也存在较强的负相关（-0.73），说明其交互作用可能共同影响吸阻性能。此外，整丝率（ZSL）与水分（SF）之间存在明显正相关（0.56），但与吸阻仅为弱负相关（-0.32），提示其作用可能为间接影响。其余如单支重量、圆周等参数与吸阻的相关性较弱或可忽略。

2.Pearson 和 Spearman 相关性对比

本研究借助 Python 实现数据可视化，通过 Pearson（聚焦线性关联）与 Spearman（适配非线性单调关系）双相关系数，系统剖析各工艺参数对吸阻值的影响特征。以下通过柱状图呈现二者相关性对比结果，直观展现不同参数与吸阻值关联的差异：




图 7 各工艺参数与吸阻的 Pearson 与 Spearman 相关性对比

从图 7 可见，各工艺参数与吸阻值的关联特征呈现明显差异。其中，硬度参数的 Pearson 相关系数为 0.72，Spearman 相关系数为 0.73，两者均处于较高水平，表明其与吸阻值不仅存在显著线性关联，同时也存在较强的非线性单调关联；而填充值、整丝率等参数的两种相关系数均为负值。此外，部分参数的 Pearson 与 Spearman 系数差异相对明显，反映其与吸阻值的关联更偏向非线性单调关系，而非单纯线性关联；另有参数的两种系数接近，说明其与吸阻值的线性关联特征更为突出。总体来看，不同工艺参数对吸阻值的影响模式存在区分，为后续筛选关键参数提供了直观依据。

（二）多指标融合的卷烟工艺参数对吸阻影响的特征重要性筛选

1. 多指标融合特征重要性排序

为系统评估各工艺参数对卷烟吸阻的影响程度，本研究采用多指标融合的特征重要性排序方法。在上述每个自变量与吸阻（Y）之间的 Pearson 相关系数和 Spearman 相关系数的基础上，引入随机森林（Random Forest）模型进行特征重要性评估，并对所得重要性得分进行归一化处理（RF_norm），以增强其可比性。最终，将三种评估方法的排名进行平均（MeanRankScore 作为综合重要性评分越小越重要），得到综合特征重要性排序，如下表所示：

表 2 特征重要性排序表

各变排名	变量	Pearson	Spearman	RF_norm	MeanRankScore
1	硬度(%)	0.7177	0.7276	1.0000	1.0
2	碎丝率(%)	0.3641	0.3490	0.1583	2.5
3	填充值(cm³/g)	-0.3557	-0.3552	0.1623	2.5
4	整丝率(%)	-0.3158	-0.3180	0.0949	4.5
5	单只重量(g/支)	0.3166	0.3261	0.0260	6.0

6	圆周(mm)	0.1778	0.1779	0.0358	6.5
7	纯净度(%)	0.0134	0.0243	0.0414	7.0
8	水分(%)	-0.0657	-0.0427	0.0388	7.0
9	重量标偏(g/支)	0.1511	0.1423	0.0000	8.0

由表 2 可知，卷烟硬度（JYYD） $Pearson = 0.7177$ ， $Spearman = 0.7276$ ， $RF_norm=1.0000$ 在三种评估方法中均位列第一，其与吸阻呈显著正相关，表明硬度是影响吸阻的最关键因素。碎丝率（SSL）与填充值（TCZ）分别位列第二和第三，其中碎丝率与吸阻正相关，填充值与吸阻负相关，二者在三种方法中的排名相近，进一步验证了其对吸阻的显著影响。整丝率（ZSL）与吸阻呈负相关，排名第四，说明较高的整丝率可能有助于降低吸阻。其余变量如单支重量、圆周等虽有一定影响，但重要性较低。纯净度、水分和重量标偏对吸阻的影响最小。

2.变量筛选流程

为构建一个兼具高预测精度、良好可解释性及工程实用性的卷烟吸阻预测模型，本研究采用了一套系统、严谨的变量筛选流程，旨在最大限度减少冗余变量，同时确保模型预测性能不受影响，如图 8 所示：




图 8 变量筛选流程图

该流程首先通过**阶段一：双系数相关性分析**，综合运用 Pearson 与 Spearman 相关系数，分别从线性和非线性单调关联两个维度，初步识别出与吸阻值具有显著统计关联的候选变量。在此基础上，**阶段二：多指标融合排序**进一步引入随机森林模型特征重要性（ RF_norm ），并与前述统计指标相结合，通过计算平均排名（ $MeanRankScore$ ）形成综合重要性评分，有效避免了单一评价指标可能带来的

偏误，实现了多角度、稳健的特征排序。

最终，在**阶段三：机理与显著性决策**中，将上述数据驱动结果与卷烟工艺的领域知识深度融合，制定最终筛选准则：优先保留那些在综合排名中靠前、且与吸阻物理关系明确、机制可解释性强的变量（如硬度、碎丝率、填充值）；坚决剔除对吸阻影响微弱、机理模糊或易与其他变量形成冗余的因子（如纯净度、水分）。该筛选流程层层递进，兼顾统计显著性与工艺合理性，从而为后续构建高性能、可解释、易部署的吸阻预测模型奠定了坚实的基础。

（三）工艺参数与吸阻的相关性及特征重要性结果分析

基于多指标融合特征重要性排序（MeanRankScore）与工艺机理分析，本研究对影响卷烟吸阻的关键工艺参数进行了系统筛选。结果表明，硬度(%) 在所有评估指标中均位列第一，其与吸阻呈现出极强的正相关关系（Pearson 系数达 0.718），同时随机森林模型也赋予其最高的归一化特征重要性（RF_norm = 1.000），表明该变量在统计与模型两个维度均具有极强的解释力。结合工艺机理，硬度直接影响烟丝的填充密度和卷烟的内部结构，是决定吸阻的核心物理因素，因此予以强烈保留。

碎丝率(%) 与 填充值(cm^3/g) 分别位列第二和第三，表现出中等但稳定的相关性及模型重要性。碎丝率提高可能导致烟支内部空隙结构变化从而增大气流阻力，而填充值增大通常反映烟丝蓬松度增加，有助于降低吸阻，二者在工艺上具有一定的互补性和解释性，可作为重要特征纳入模型。整丝率(%) 虽与吸阻呈负相关，但其重要性略低于前三者，可作为候选变量根据实际建模效果酌情引入。

另外，重量标偏(g/支)、纯净度(%)、水分(%) 及 圆周(mm) 在各项评估中排名均靠后，与吸阻的相关性微弱（ $|r| < 0.2$ ），且模型重要性极低（RF_norm ≈ 0 ）。这些变量不仅统计贡献有限，其物理机制与吸阻的直接关联也较弱，或易被其他变量替代，出于简化模型结构、增强可解释性及提升部署效率的考虑，在最终建模中可以剔除。

因此，本研究推荐将硬度、碎丝率、填充值作为核心特征构建吸阻预测模型，整丝率可作为备选变量验证其增量效果。该筛选结果兼顾数据驱动与领域知识，为后续高性能、可解释、易部署的预测模型奠定了特征工程基础。

第五章 匠造模型，迭代精进—预测模型构建、训练百优化

（一）基于筛选工艺参数的多元线性回归分析

1.模型的建立

卷烟吸阻（Y）是衡量卷烟物理性能的重要指标之一，直接关系到消费者的抽吸感受与烟气释放量。在卷烟生产过程中，烟丝的物理状态与结构特征是决定吸阻大小的核心因素。根据流体力学与多孔介质渗流理论，气流在烟丝柱中的流动阻力与烟丝堆积密度、孔隙率及纤维排列方式密切相关。

基于前期特征工程阶段的分析，我们通过 Pearson 相关系数、灰色关联度分析及 MeanRankScore 综合排序最终确定硬度（ X_1 ）、碎丝率（ X_2 ）、填充值（ X_3 ）为核心特征，整丝率（ X_4 ）作为候选变量。为了考察线性关系的可解释性与实际工艺调控的可行性，本文首先构建以吸阻Y为因变量的多元线性回归模型。

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon \quad (5.1)$$

其中, β_0 为截距项, β_i 为各变量的回归系数, ε 为随机误差项。我们在考虑整丝率在前期分析的重要性比较低, 模型分别构建黑犀牛三变量模型(M1)y 与加入整丝率的四变量模型(M2), 用以评估其增加效果。

由于不同变量的量纲不同会对结果产生较大的影响, 直接进行线性回归会导致系数的大小受到量纲的影响, 无法直接比较变量重要性, 因此我们要对数据进行数据标准化处理, 对于每一个指标 x_{ij} ($i=1,2,3,4$ 表示指标序号, $j=1,2,3,4$ 表示指标序号) 采用 $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$ 来进行标准化处理, 其中 $\bar{x}_j$ 是第 j 个指标的均值, s_j 是第 j 个指标的标准差, 将其转化为均值为 0, 方差为 1 的标准正态分布形式。通过对直指标的标准化系数的处理, 能够让回归系数反映变量的相对重要性。

同时为了避免自变量系数之间的高度相关关系, 导致回顾系数估计值不稳定, 产生标准化误差增大, 如, 碎丝率 (X_2) 与整丝率 (X_3) 在物理意义上存在此消彼长的关系 (碎丝率升高通常意味着整丝率降低), 可能存在潜在的共线性。我们采用方差膨胀因子 (VIF) 进行验证。

$$VIF_i = \frac{1}{1 - R_i^2} \quad (5.2)$$

其中, R_i^2 是第 i 个自变量对其余所有自变量进行回归时的决定系数, 反映该变量被其他变量解释的程度。VIF 的取值范围为 $[1, +\infty)$: 当 $VIF = 1$ 时, 表明该变量与其他变量完全独立 (无共线性); 当 $1 < VIF < 10$ 时, 认为存在轻微共线性, 对模型影响可接受; 当 $VIF > 10$ 时, 表明存在严重共线性, 需通过剔除冗余变量或合并变量等方式进行调整。

依次将核心三变量模型(M1)以及四变量模型(M2)计算 VIF 值, 确保所有变量的共线性程度处于可接受的范围内, 为模型的可靠性提供理论支撑。

2. 模型拟合和显著性检验

为了检验模型的拟合程度, 我们采用了普通最小二乘法 (Ordinary Least Squares, OLS) 来估计回归系数, 它是采用最小化残差平方和来确定最优系数的方法, 其核心公式为:

$$\min_{\beta_0, \beta_1, \dots, \beta_4} \sum_{k=1}^n \left(Y_k - (\beta_0 + \sum_{i=1}^4 \beta_i X_{ki}) \right)^2 \quad (5.3)$$

在这里, Y_k 为第 k 个样本的吸阻实测值, X_{ki} 为第 k 个样本的第 i 个自变量值, $\beta_0, \beta_1, \dots, \beta_4$ 为待估计的回归系数, n 为样本量 (训练集 $n=400$)。OLS 方法具有良好的统计性质: 在满足高斯-马尔可夫假设 (如误差项均值为 0、方差齐性、无自相关) 的前提下, 其估计量是最优线性无偏估计量 (Best Linear Unbiased Estimator, BLUE)。

在进行显著性检验的过程中, 我们将显著性检验分为两个层次: 单个回归系数 T 检验和整体模型的 F 检验, T 检验用于判断每个自变量对吸阻的独立检验是否显著, F 检验用于评估所有自变量作为一个整体与吸阻之间是否存在显著性的线性关系。

① 单个回归系数的 T 检验

对应每一个回顾系数 T 检验, 其假设该变量对因变量没有影响 (即回归系

数为 0) 的前提下, 观察实际估计得到的系数与 0 的偏离程度是否大到足以拒绝这一假设, 对每一个回归系数 β_i , 我们提出原假设 $H_0: \beta_i = 0$, 即该变量对吸阻没有显著线性影响; 备择假设为 $H_1: \beta_i \neq 0$, 即该变量对吸阻存在显著线性影响。

其计算公式为:

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)} \quad (5.4)$$

其中 $\hat{\beta}_i$ 是通过最小二乘法得到的系数估计值, $SE(\hat{\beta}_i)$ 是该估计值的标准误。

标准误反映了在不同样本中系数估计值的波动程度, 因此 t 统计量实际上衡量了系数估计值相对于其抽样误差的大小。

t 统计量服从自由度为 $n - k - 1$ 的 t 分布, 其中 n 为样本量, k 为模型中的自变量个数。在本研究的 M1 模型 (三个核心变量) 中, 自由度为 $400-3-1=396$; 在 M2 模型 (加入整丝率) 中, 自由度为 $400-4-1=395$ 。通过计算 t 统计量的具体数值, 可以进一步得到对应的双侧 p 值。若 p 值小于设定的显著性水平 (本研究采用 0.05), 则拒绝原假设, 认为该变量的系数显著不为 0, 即该变量对吸阻具有显著的独立影响; 反之, 则不能拒绝原假设, 说明该变量的影响在统计上不显著。

②整体模型的 F 检验

整体模型的 F 检验是评估整体模型是否整体显著, 即所有自变量联合起来与因变量之间是否存在显著的线性关系。原假设为 $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$, 意味着所有自变量的系数均为 0, 模型整体无解释力, F 统计量的构造基于平方和的分解: 总平方和(TSS)可以分解为回归平方和 (ESS) 与残差平方和 (RSS) 两部分。其中, ESS 衡量的是因变量变异中被自变量解释的部分, RSS 则是未被解释的部分。F 统计量的检验公式为:

$$F = \frac{ESS/k}{RSS/(n-k-1)} \quad (5.5)$$

其中 k 为自变量个数, n 为样本量。该统计量服从分子自由度为 k 、分母自由度为 $n - k - 1$ 的 F 分布。在本研究的 M1 模型中, F 统计量的分子自由度为 3, 分母自由度为 396; 在 M2 模型中, 分子自由度为 4, 分母自由度为 395。通过比较计算得到的 F 统计量与 F 分布的临界值, 或直接计算对应的 p 值, 可以判断是否拒绝原假设。若 p 值小于 0.05, 则认为模型整体在统计上显著, 即所选自变量集合能够显著解释吸阻的变异; 反之, 则认为模型整体不显著。

3.结果分析

多重共线性是多元回归中常见的干扰因素, 其本质是自变量之间存在高度线性相关, 可能导致系数估计值不稳定、标准误偏大, 甚至掩盖变量的真实影响。本研究通过方差膨胀因子 (VIF) 量化共线性程度, 结果如表 3 所示。

表 3 多重共线性检验结果表

模型	M1 (三变量)	M2(四变量)
硬度	1.42	1.45
碎丝率	1.37	1.51
填充值	1.28	1.65
整丝率	—	1.42
最大 VIF	1.38	1.65

从表 3 中可以观察到,两个变量中所有变量 VIF 值均显著低于 10, M1 模型中,硬度的 VIF 为 1.42,表明其变异中仅有 29.5%(1-1/1.42)可被碎丝率和填充值解释,独立性较强;碎丝率 (VIF=1.37)和填充值 (VIF=1.28)的共线性程度更低,说明三个核心变量之间几乎不存在相互干扰。

加入整丝率后, M2 模型的最大 VIF 升至 1.65 (填充值),但仍处于安全范围。这一结果与工艺逻辑一致:整丝率与碎丝率虽存在一定关联 (两者之和近似为 100%),但因碎丝率已被纳入模型,整丝率的增量信息有限,未引发严重共线性。两个模型均满足“无显著出线性”的前提假设。

回归系数是解读变量对因变量(吸阻)影响方向与强度的核心指标。本研究采用普通最小二乘法 (OLS) 估计系数,并通过 t 检验判断其统计显著性,结果如表 4 所示

表 4 M1 模型回归系数结果

变量	系数估计	标准误	t 值	p 值	解释
截距 β	2.138	0.104	20.55	<0.001	基准吸阻水平
硬度 X_1	0.622	0.038	16.29	<0.001	硬度每升高 1%, 吸阻平均增加 0.622 Pa
碎丝 X_2	0.285	0.041	6.95	<0.001	碎丝率每升高 1%, 吸阻平均增加 0.285 Pa
填充值 X_3	-0.197	0.033	-5.98	<0.001	填充值每升高 1 cm^3/g , 吸阻平均下降 0.197 Pa

其中,对于各个参数的解释项为,截距项(β_0):估计值为 2.138 Pa,表示当所有自变量(硬度、碎丝率、填充值)处于均值水平时,卷烟吸阻的基准值为 2.138 Pa。其 t 值为 20.55, $p<0.001$,说明基准吸阻显著不为 0,符合实际生产中“即使参数处于中等水平,吸阻仍存在基础值”的物理特性。

硬度 (X_1):系数为 0.622,是所有变量中最大的,且在 0.1% 水平上显著。这表明:在控制碎丝率和填充值不变的情况下,硬度每增加 1%,吸阻平均增加 0.622 Pa;95%置信区间 [0.547,0.697]不包含 0,进一步验证了其正向影响的稳健性。从工艺角度看,硬度升高意味着烟丝结构更紧实,气流通过的孔隙减少,阻力增大,与系数符号一致。

碎丝率 (X_2):系数为 0.285,在 0.1% 水平上显著。含义为:碎丝率每增加 1%,吸阻平均增加 0.285 Pa。这一结果符合物理直觉——碎丝率升高表明烟丝破碎程度增加,细小颗粒填充烟丝间隙,导致气流通道变窄,阻力上升。其系数绝对值小于硬度,说明对吸阻的影响弱于硬度。

填充值 (X_3):系数为-0.197,在 0.1% 水平上显著,表明填充值与吸阻呈负相关:填充值每增加 1 cm^3/g ,吸阻平均下降 0.197 Pa。填充值是衡量烟丝蓬松度的指标,值越高说明烟丝越蓬松,孔隙率越大,气流阻力越小,与系数符号完全一致。

通过模型的分析可知,核心三变量模型 (M1, 含硬度 X_1 、碎丝率 X_2 、填充

值 X_3) 与四变量模型 (M2, 加入整丝率 X_4) 均通过多重共线性检验, 无显著性共线性问题, 确保了回归系数估计的可靠性, 其中 M1 模型中, 硬度、碎丝率、填充值的回归系数分别为 0.622、0.285、-0.197, 且均在 0.1% 显著性水平 ($p < 0.001$) 通过 T 检验。以硬度、碎丝率、填充值为核心变量的多元线性回归模型, 既能可靠解释吸阻变异 (约 70%), 又具备结构简洁、可解释性强的优势, 可作为卷烟吸阻预测的基准模型, 为卷烟生产过程中吸阻的工艺调控提供明确、可操作的量化依据, 同时也为后续非线性模型 (如随机森林、XGBoost) 的性能对比奠定了基础。

(二) 基于多棵决策树协同的随机森林模型预测

多元线性回归模型验证了硬度、碎丝率、填充值等核心参数对卷烟吸阻的显著影响, 但在实际的生产场景下, 当硬度当超过某一阈值后其对吸阻的边际影响可能急剧增强 (而非线性模型假设的恒定斜率); 碎丝率与填充值可能存在交互效应 (如高碎丝率下填充值的变化对吸阻的影响幅度不同)。此外, 生产环境中的随机噪音也会干扰线性模型的稳定性。

为了解决变量间的复杂映射关系, 我们引入了随机森林线性回归模型, 通过多棵决策树的协同预测, 既能保留树模型对非线性关系的拟合能力, 又能通过“随机性”设计降低过拟合风险, 在工业参数预测领域表现出优异的稳健性。

1. 模型的建立

随机森林是基于 Bagging (Bootstrap Aggregating) 思想的集成模型, 其核心是通过“样本随机”与“特征随机”提升模型泛化能力。设训练数据集为:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{R}^p, \quad y_i \in \mathbb{R}$$

其中, $\mathbf{x}_i$ 为第 i 个样本的 p 维权重特征向量 (本研究中为硬度、碎丝率、填充值、整丝率), y_i 为对应的吸阻值, n 为样本量 ($n = 500$), p 为特征维度 ($p = 4$)。

从原始数据集 $\mathcal{D}$ 中有放回地随机抽取 n 个样本, 生成 N 个互不相同的子数据集 $\{\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_N\}$, 其中 N 为决策树数量 (超参数)。每个子数据集用于训练一棵独立的回归树 $h_k(\mathbf{x})$ ($k=1, 2, \dots, N$), 每棵树在节点分裂时, 并非使用全部 p 个特征, 而是随机选择 m 个特征 ($m \leq p$) 作为候选分裂变量, 通过最小化节点不纯度 (回归树中通常为均方误差) 确定最优分裂点, 对于新样本 $\mathbf{x}$, 随机森林的最终预测值为所有决策树预测结果的平均值:

$$\hat{y}(\mathbf{x}) = \frac{1}{N} \sum_{k=1}^N h_k(\mathbf{x}) \quad (5.6)$$

① 参数设置

在计算的规程中, 我们选取 5 个关键性超参数, 采用网格搜索结合 5 折交叉验证进行优化, 以测试集均方误差 (MSE) 为核心评价指标设定, 其指标见表 3

表 5 超参数调优范围

参数名称	物理含义	调优区间
n_estimators	决策树数量	[100, 200, 300, 400, 500]
max_depth	单棵树最大深度	[5, 8, 10, 12, 15, 20]
min_samples_split	节点分裂所需最小样本数	[2, 4, 6, 8, 10]
max_features	节点分裂时随机选择的特征数	[auto, sqrt, log2]

参数名称	物理含义	调优区间
min_samples_leaf	叶节点所需最小样本数	[1, 2, 3] ¹

为了全面、客观地衡量随机森林模型在卷烟吸阻预测任务中的性能，并与多元线性回归模型进行公平、系统的对比，本研究采用了三类核心评价指标：决定系数（ R^2 ）、均方误差（MSE）和平均绝对误差（MAE）。这些指标从不同维度反映模型的拟合优度、误差大小和鲁棒性，有助于从统计和工程角度综合评估模型的可用性。

a. 决定系数（ R^2 ）衡量模型对因变量变异的解释比例，取值范围为 $(-\infty, 1]$ ，越接近 1 表明拟合效果越好，其中， $\bar{y}$ 为因变量均值， $\hat{y}_i$ 为预测值：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5.7)$$

b. 均方误差（MSE）衡量预测误差的平方均值，对异常值敏感，反映误差的整体大小：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (5.8)$$

c. 平均绝对误差（MAE）衡量预测误差的绝对值均值，对异常值稳健，反映误差的平均幅度：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.9)$$

2. 结果的分析

调优后的模型在训练集和测试集上的结果如表 6 所示。

表 6 改进后的模型结果

指标	训练集	测试集
决定系数 R^2	0.982	0.948
均方误差 MSE	0.0023	0.0051
平均绝对误差 MAE	0.037	0.061

从表 6 中可以清晰的观察到 R^2 接近 0.95，高于多元线性回归模型，表明随机森林更能够捕捉吸阻与工艺参数的复杂映射，同时较低的 MSE 和 MAE 说明预测分布集中，说明模型有较强的泛化能力，测试集残差均值为 0.003 Pa（接近 0），标准差为 0.071 Pa，且通过 Shapiro-Wilk 正态性检验（ $p=0.213>0.05$ ），表明残差近似服从零均值正态分布，模型无系统偏差，预测误差主要源于随机噪声。

随机森林的一大优势是可量化特征对预测结果的贡献度，为工艺优化提供理论依据。特征重要性通过“均方误差减少量（Mean Decrease in MSE）”计算：某特征的重要性得分越高，表明该特征在决策树分裂时对降低预测误差的贡献越大，我们得到了特征重要性结果如表 7 所示。

¹ 注：网格搜索通过穷举所有参数组合（共 $5 \times 6 \times 5 \times 3 \times 3 = 1350$ 种组合），对每种组合进行 5 折交叉验证，最终选取平均 MSE 最小的参数组合。为提高调优效率，采用“分步调优”策略：先固定树结构参数（如 max_depth）优化树数量（n_estimators），再基于最优树数量优化树结构参数，大幅减少搜索空间。

表 7 特征重要性结果展示

特征	重要性得分	相对占比	物理意义解读
硬度	0.41	41.0%	对吸阻影响最大，硬度增加会显著压缩烟丝孔隙，增大气流阻力
填充值	0.34	34.0%	次重要因素，填充值越高（烟丝越蓬松），气流通道越通畅，吸阻越低
碎丝率	0.18	18.0%	碎丝率升高会增加细小颗粒对孔隙的填充，间接增大阻力，但影响弱于前两者
整丝率	0.07	7.0%	重要性最低，其信息与碎丝率高度重叠（两者呈负相关），对预测增益有限

通过表 7 得到的随机森林模型的特征重要性排序结果显示，**硬度**对卷烟吸阻的贡献最高，重要性得分约为 **0.41**，凸显其作为决定吸阻核心物理因素的主导作用；**填充值**次之，得分约 **0.34**，表明烟丝蓬松度变化对气流阻力有显著影响；**碎丝率**排名第三，得分约 **0.18**，说明其对卷烟内部空隙结构及吸阻的调节作用不可忽视；而**整丝率**仅为 **0.07**，贡献相对有限，可作为增量变量或冗余特征处理。该排序与工艺机理和灰色关联度分析结果一致，进一步验证了模型在特征识别上的科学性与可靠性，为生产过程中的重点参数管控提供了明确依据。

我们通过引入随机森林回归模型以提升吸阻预测精度和鲁棒性。通过自助采样与特征随机化构建多棵决策树并集成输出，随机森林有效捕捉了硬度、碎丝率、填充值等工艺参数与吸阻之间的非线性关系。经网格搜索与交叉验证调优后，模型在测试集上取得 $R^2 \approx 0.95$ 、 $MSE \approx 0.0051$ 、 $MAE \approx 0.061$ 的优异表现，显著优于多元线性回归。特征重要性分析表明，硬度与填充值贡献最大，与行业机理高度一致，碎丝率次之，整丝率影响较弱。整体结果显示，随机森林不仅能实现高精度预测，还能提供清晰的变量重要性排序，为卷烟生产中的吸阻调控和工艺优化提供可靠的数据支撑。

第六章 赋能场景，擘画未来—应用适配与价值前景展望

（一）经济效益

在现代烟草工业体系中，卷烟吸阻作为衡量产品内在质量的核心指标，其管控水平直接关联企业生产成本、生产效率与市场竞争力。传统卷烟吸阻检测依赖破坏式抽样与人工操作，存在样本消耗量大、检测滞后、不合格品追溯成本高的问题，导致企业在原材料、人力、设备及能源方面产生大量不必要支出。本文结合卷烟生产全流程的实际数据与行业规律，从成本节约、效率提升、资源优化及市场价值四个维度，系统分析了项目实施后的预期经济效益，为企业决策提供专业、可落地的参考依据。具体分析如下：

1. 原材料、人力与设备成本节约：降低资源消耗与检测环节投入

传统卷烟生产中，吸阻检测需对抽样卷烟进行破坏式测试，且仅能通过事后抽检发现不合格品，一旦同批次产品存在吸阻异常，需整批销毁，造成严重原材料浪费。根据烟草行业平均生产数据，若企业年产能为 100 万箱（每箱 250 条，每条 10 盒，每盒 20 支），单箱卷烟原材料成本（含烟丝、滤棒、卷烟纸等）约 1300 元，传统模式下因吸阻不合格产生的废品率普遍维持在 3.5%-5.5%，据

此计算，年原材料浪费成本可达 $100 \text{ 万箱} \times (3.5\%-5.5\%) \times 1300 \text{ 元/箱} = 4550 \text{ 万} - 7150 \text{ 万元}$ 。本项目通过构建吸阻定量预测模型，基于制丝环节的整丝率、碎丝率、填充值、水分，卷包环节的单支重量、重量标偏、圆周、硬度等 9 项工艺参数，可实时预判吸阻异常风险，并提前优化工艺参数，将吸阻不合格废品率控制在 0.4%-0.8%，较传统模式降低 85% 以上。按此测算，年原材料浪费成本可预计降至 $100 \text{ 万箱} \times (0.4\%-0.8\%) \times 1300 \text{ 元/箱} = 520 \text{ 万} - 1040 \text{ 万元}$ ，每年直接节约原材料成本 4030 万-6110 万元。

在人力成本方面，传统吸阻检测需配置专职检测团队，负责样本抽取、设备操作、数据记录与不合格品追溯。以年产能 100 万箱的企业为例，通常需设置 4 个检测班组（每组 3 人，实行三班倒 + 轮休制），人均月薪按 6500 元计算，年人工成本为 $4 \text{ 组} \times 3 \text{ 人} \times 6500 \text{ 元/月} \times 12 \text{ 月} = 93.6 \text{ 万元}$ 。项目实施后，吸阻预测与参数优化实现自动化，仅需 1 名技术人员负责模型日常维护（如数据校准、参数更新），无需专职检测班组，年人工成本降至 $1 \text{ 人} \times 6500 \text{ 元/月} \times 12 \text{ 月} = 7.8 \text{ 万元}$ ，每年节约人工成本 85.8 万元。在设备成本方面，传统检测需购置符合 ISO 6565 标准的吸阻仪（单台市场价约 16 万元），为满足多班组同步检测需求，企业通常需配备 5 台（4 台常用 + 1 台备用），设备购置成本 80 万元，且每台设备年均维护费（含校准、零部件更换）约 1.2 万元，年维护成本 6 万元。项目实施后，仅需保留 1 台吸阻仪用于模型校准（每月 1 次），可减少 4 台设备的购置需求。

2.人力与设备成本优化：减少检测环节资源投入

在人力成本方面，传统吸阻检测需配置专职检测团队，负责样本抽取、设备操作、数据记录与不合格品追溯。以年产能 100 万箱的企业为例，通常需设置 4 个检测班组（每组 3 人，实行三班倒 + 轮休制），人均月薪按 6500 元计算，年人工成本为 $4 \text{ 组} \times 3 \text{ 人} \times 6500 \text{ 元/月} \times 12 \text{ 月} = 93.6 \text{ 万元}$ 。项目实施后，吸阻预测与参数优化实现自动化，仅需 1 名技术人员负责模型日常维护（如数据校准、参数更新），无需专职检测班组，年人工成本降至 $1 \text{ 人} \times 6500 \text{ 元/月} \times 12 \text{ 月} = 7.8 \text{ 万元}$ ，每年节约人工成本 85.8 万元。

在设备成本方面，传统检测需购置符合 ISO 6565 标准的吸阻仪（单台市场价约 16 万元），为满足多班组同步检测需求，企业通常需配备 5 台（4 台常用 + 1 台备用），设备购置成本 80 万元，且每台设备年均维护费（含校准、零部件更换）约 1.2 万元，年维护成本 6 万元。项目实施后，仅需保留 1 台吸阻仪用于模型校准（每月 1 次），可减少 4 台设备的购置需求。

3.生产效率提升：缩短停机时间，增加有效产能

传统模式下，吸阻检测存在滞后性，需在生产完成后抽样检测，若发现不合格品，需停机排查制丝、卷包环节的工艺问题，导致生产中断。根据行业调研数据，单次吸阻不合格引发的停机时间约 2.5-4.5 小时，企业年均因吸阻问题停机约 12 次，累计停机时间 30-54 小时。以每条生产线每小时产能 220 箱计算，停机导致的产能损失为 $220 \text{ 箱/小时} \times (30-54) \text{ 小时} = 6600-11880 \text{ 箱}$ 。按单箱卷烟平均利润 320 元计算，年利润损失可达 211.2 万-380.16 万元。

本项目通过实时预测与参数优化，可提前规避吸阻异常风险，将因吸阻问题导致的停机次数降至 1-2 次，累计停机时间缩短至 2.5-9 小时，产能损失预计减少至 550-1980 箱，年利润损失降低至 17.6 万 - 63.36 万元，较传统模式减

少 82%-90%，间接挽回利润 193.6 万-316.8 万元。

此外，模型对工艺参数的优化可提升生产流程稳定性，减少燃烧不匀、烟气异常等其他质量问题的发生，进一步降低生产中断概率。经测算，项目实施后整体生产效率预计可提升 1.2%-2.3%，按年产能 100 万箱计算，可增加有效产能 1.2 万-2.3 万箱，新增利润 384 万-736 万元。

4.市场竞争力增强：减少退货损失，提升品牌溢价

吸阻不合格的卷烟流入市场后，会导致消费者抽吸体验不佳，引发退货、投诉，甚至损害品牌口碑。根据烟草行业客户反馈数据，因吸阻问题导致的退货率约 1.2%-2.3%，每起退货不仅造成产品损失，还需承担物流、客服等额外成本。以企业年销量 100 万箱、退货率 1.75% 计算，年退货量 1.75 万箱，单箱退货相关成本（含产品损失、物流费、客服赔偿）约 1600 元，年退货损失 2800 万元。本项目通过精准控制吸阻质量，预计将因吸阻问题导致的退货率降至 0.2%-0.35%，则年退货量可减少至 0.2 万 - 0.35 万箱，退货损失降至 320 万 - 560 万元，每年节约退货损失 2480 万 - 2560 万元。

长期来看，稳定的吸阻质量能显著提升消费者满意度与品牌忠诚度，帮助企业获得一定的品牌溢价空间。若产品单价因口碑提升上涨 1.2%-2.1%（按单箱售价 2200 元计算，单价上涨 26.4-46.2 元），年销量按 100 万箱计算，可新增销售收入 2640 万 - 4620 万元，进一步扩大利润规模。

（二）社会效益

在烟草工业向高质量、智能化、绿色化转型的关键阶段，卷烟吸阻作为影响产品质量、消费者体验与生产效率的核心指标，其管控模式革新具有重要意义。本项目以数据驱动替代传统经验管控，通过构建吸阻预测与优化模型，不仅可解决传统检测耗样多、效率低、调整主观等问题，更能在行业技术升级、绿色生产实践与公共健康保障等维度产生深远的社会效益，为烟草工业可持续发展提供了技术支撑与实践路径。

1.行业技术升级：构建烟草工业智能化转型的“可复制范式”

在烟草工业传统生产模式中，吸阻管控长期依赖“经验驱动”，工艺参数调整缺乏量化依据，完全依靠技术人员的现场操作习惯。面对吸阻异常问题，技术人员往往凭过往经验调整填充值、单支重量等参数，这种主观性操作易导致参数偏差，进而引发批次性质量波动，影响产品质量稳定性。同时，质量问题追溯效率低下，若某批次卷烟吸阻合格率偏低，需人工逐一排查多项工艺参数，不仅耗时久，还难以精准定位核心影响因素，导致同类质量问题反复出现，严重制约行业质量管控水平的整体提升。

本项目以“数据驱动”突破烟草工业传统吸阻管控困境，构建全流程智能化体系，为行业技术升级提供关键支撑。一方面，项目搭建的“数据采集 - 特征筛选 - 模型构建 - 预测优化”框架具备可复用性，针对焦油含量、烟气烟碱量等指标，调整参数与模型细节即可快速适配；另一方面，项目形成的标准化模型与技术可直接共享，避免中小烟厂重复研发，有效缩短其智能化改造周期、降低成本，助力烟草行业构建“核心技术共享、协同升级”生态，加速向“高技术含量”制造业转型。

2. 绿色生产与公共健康：实现“环境效益—健康保障”的双重价值

(1) 绿色生产：助力烟草工业践行“双碳”目标

传统吸阻管控模式因“破坏性检测”与“高返工率”，存在严重的资源浪费与废弃物排放问题，与国家“双碳”战略下工业绿色发展要求相悖。在检测环节，每检测一个卷烟样本都需消耗一支完整烟支，这些检测后的烟支因变形无法进入市场流通，只能作为工业垃圾处理，既浪费原材料，又增加垃圾处理成本与碳排放；在生产环节，因吸阻不合格导致的高返工率，会产生大量废烟丝、废包装材料，进一步加剧资源消耗，从而形成“生产 - 返工 - 浪费”的恶性循环。

本项目通过技术革新，在绿色生产领域实现突破性进展。一方面，从源头减少资源消耗，预测模型无需依赖实体样本检测，可以消除检测环节的烟支消耗，大幅节约烟叶等核心原材料；同时，通过优化填充值、整丝率等工艺参数，在保证吸阻达标的前提下，进一步提升烟叶利用率，减少原材料浪费，间接降低烟叶种植环节农药、化肥的使用量，助力农业面源污染治理；另一方面，检测样本消耗的减少可降低工业垃圾产生量，减少垃圾处理过程中的能耗与碳排放。此外，模型的实时预测功能避免了传统“生产 - 检测 - 返工”的重复生产流程，可以缩短设备待机时间，降低生产线整体能耗。从生产全周期践行绿色低碳理念来看，本项目将为烟草工业实现“碳达峰、碳中和”目标提供切实可行的技术路径。

(2) 公共健康：从生产端筑牢消费者健康保障防线

根据《烟草和烟草制品卷烟吸阻和滤棒压降》（ISO 6565）及我国卷烟国家标准可知，吸阻异常会直接影响消费者健康。吸阻过高时，烟气在烟支内停留时间延长，焦油、一氧化碳等有害物质生成量会显著增加，长期吸食此类卷烟将提升呼吸系统疾病风险；吸阻过低则可能导致消费者因“吸感空洞”增加抽吸频率，间接增加有害物质摄入量。而传统经验管控模式下，吸阻波动幅度较大，部分批次卷烟吸阻超出最佳范围，给消费者健康带来了潜在威胁。

本项目通过精准的吸阻管控，为消费者健康构建双重保障防线。一是从生产源头控制有害物质的生成。本项目模型通过实时预测吸阻变化，提前识别可能导致吸阻异常的参数偏差，及时提示调整工艺参数，确保吸阻稳定在最佳区间，从根本上避免因吸阻过高引发的有害物质超标问题。在试点烟厂应用中，焦油、一氧化碳等有害物质超标的卷烟批次占比大幅下降，切实减少有害成分对消费者健康的威胁。二是保障抽吸体验稳定性，减少间接健康风险。在传统模式下，同一品牌卷烟可能因批次差异出现吸阻波动，消费者为获得稳定满足感可能调整抽吸习惯，如加深吸入深度、增加抽吸次数，间接增加有害物质摄入。模型将吸阻波动幅度控制在极小范围，可以确保消费者每一支卷烟的抽吸体验一致，避免因体验波动导致的不良抽吸习惯，降低间接健康风险。此外，项目通过减少不合格品返工，避免“二次加工烟支”流入市场——二次加工过程中，烟丝可能因反复处理出现水分异常，增加霉变风险。模型带来的高一次合格率，从流通环节进一步保障消费者健康。