

冰雪旅游新闻文本 挖掘与产业赋能研究

——基于 LDA+BERT 语义增强模型

目录

一、项目概述.....	3
（一）项目背景.....	3
（二）文献综述.....	4
1. 旅游文本挖掘研究进展.....	4
2. 冰雪旅游研究现状.....	4
3. 新闻报道主题与内容分析研究.....	5
4. 现有研究不足.....	6
（三）应用领域与场景.....	7
1. 政府部门.....	7
2. 冰雪旅游企业.....	7
3. 媒体机构.....	7
4. 学术研究机构.....	8
（四）主要工作内容.....	8
1. 数据采集与预处理阶段.....	8
2. 模型设计与训练阶段.....	8
3. 规律挖掘与可视化阶段.....	8
4. 成果转化与应用阶段.....	9
（五）项目创新点.....	9
1. 技术创新.....	9
2. 框架创新.....	9
3. 实践创新.....	9
二、解决方案.....	10
（一）方案设计理念与原则.....	10
（二）方案核心功能.....	10
1. 文本智能清洗功能.....	10
2. 主题自动提取与分类功能.....	11
3. 情感精准分类功能.....	11
4. 多维度关联分析功能.....	11
5. 定制化报告生成功能.....	12
（三）关键技术与实现路径.....	12
1. 文本预处理技术.....	12
2. 主题抽取与情感分析技术.....	12
3. 时空关联分析技术.....	13
（四）实现过程与关键步骤.....	13
1. 数据生成与处理.....	13
2. 数据组织与管理.....	14
3. 模型训练与优化.....	15
4. 结果分析与可视化.....	15
（五）项目实施保障.....	19
三、应用价值.....	19
（一）经济效益.....	19
1. 推动冰雪产业规模扩张与结构优化.....	19

2. 降低企业运营成本与风险损失.....	20
3. 提升媒体传播效益与广告价值.....	20
4. 带动相关产业发展与就业增长.....	20
(二) 社会效益.....	20
1. 提升公众冰雪旅游体验与满意度.....	20
2. 促进冰雪运动普及与健康中国建设.....	21
3. 推动区域均衡发展 with 乡村振兴.....	21
4. 传播冰雪文化与增强文化自信.....	21
5. 强化产业监管与规范发展.....	21
(三) 学术价值.....	22
1. 丰富旅游文本挖掘理论体系.....	22
2. 填补冰雪旅游文本专属主题体系空白.....	22
3. 提供多源数据融合研究范例.....	22
附录.....	23

一、项目概述

（一）项目背景

在“冰天雪地也是金山银山”发展理念的战略指引下，2022年北京冬奥会的成功举办成为我国冰雪经济爆发的关键催化剂，叠加国务院《关于以冰雪运动高质量发展激发冰雪经济活力的若干意见》等政策红利，冰雪产业实现从“冷资源”到“热经济”的跨越式转型。据行业权威统计，2024-2025冰雪季我国冰雪休闲旅游人次预计突破5亿，旅游收入将达6300亿元，产业整体规模正式迈入万亿元行列，成为拉动消费、优化经济结构、推动区域协调发展的核心新动能。

冰雪旅游新闻文本作为产业信息传播的核心载体，广泛分布于党报官网（如《人民日报》、《吉林日报》）、行业垂直平台（如《冰雪运动》期刊）、社交媒体（如抖音、小红书）等多元渠道，涵盖政策解读、景区推介、赛事报道、游客反馈等全链条内容。然而，这类文本存在三大核心痛点：

一是碎片化严重，主题分散于“政策扶持”“设施建设”“游客体验”等多个维度，缺乏系统性整合，难以形成产业发展全貌认知；

二是噪声干扰突出，“标题党”（含“震惊”“必看”等煽动性词汇）、广告植入（含“购票链接”“限时优惠”等商业信息）占比超6%，严重影响信息提取准确性；

三是专业术语识别难，“雪道等级划分”“冰壶赛事规则”“造雪机技术参数”等领域术语语义特殊，传统文本处理方法识别精度不足50%，导致产业关键技术与运营信息挖掘不充分。

从现有研究来看，冰雪旅游文本分析领域仍存在明显短板：技术层面，多数研究依赖单一LDA主题模型或基础词频统计，缺乏预训练语言模型（如BERT）的深度融合，语义理解深度不足；主题体系层面，未构建针对冰雪旅游的专属分类框架，对“冰雪+体育”“冰雪+乡村振兴”等新兴融合主题覆盖空白；分析维度层面，多聚焦单一主题或情感分析，缺乏“主题—情感—地域—时间”多维度联动，无法揭示产业动态演化规律与区域差异特征。在此背景下，亟需通过技术创新构建精准的文本挖掘体系，为冰雪产业高质量发展提供数据支撑与决策依据。

（二）文献综述

1. 旅游文本挖掘研究进展

旅游文本挖掘作为旅游管理与自然语言处理交叉领域的核心方向，其发展历程与技术迭代深度绑定，可清晰划分为三个阶段：

（1）人工编码阶段

该阶段研究依赖研究者对文本内容的主观解读与分类，例如通过人工标注旅游评论中的“景观评价”“服务反馈”等维度来分析游客感知。但此类方法存在显著局限，单条文本标注耗时约 15 分钟，效率极低，且不同标注者一致性系数仅 0.6-0.7，主观性强，难以适用于大规模文本数据，仅能支撑小样本案例研究。

（2）传统机器学习阶段

随着机器学习技术的成熟，LDA 主题模型凭借“自动化识别潜在主题结构”的优势，成为旅游文本挖掘的主流工具。陈涛^[1]在个性化旅游新闻推荐研究中，以 10 万条旅游类新闻为数据集，通过优化 LDA 超参数（ $\alpha=0.05$ 、 $\beta=0.01$ ），实现“目的地推荐”“旅游攻略”等主题的自动化抽取，主题识别准确率达 78%，为冰雪旅游新闻的主题提取提供了可借鉴的技术路径，其参数优化思路也为本项目 LDA 模型设置提供了重要参考。

（3）预训练语言模型阶段

BERT、GPT 等预训练语言模型的出现，推动旅游文本挖掘进入“语义深度理解”新阶段。这类模型通过大规模通用语料预训练，具备更强的歧义消解与专业术语识别能力，在主题抽取与情感分析中表现出显著优势。杨春梅等^[2]以哈尔滨冰雪旅游为研究对象，采集携程、马蜂窝等平台 8000 条游客评论，采用“词频统计+BERT 情感分析”的方法，提取出“冰雪娱乐”“交通住宿”“服务质量”等高频主题，情感分析准确率达 87%，首次将预训练模型应用于冰雪旅游文本分析，验证了该技术在冰雪领域的适用性。此外，部分学者尝试融合 LDA 与 BERT 模型，形成“主题框架+语义优化”双重验证机制，为本文“LDA+BERT”混合模型的构建提供了核心思路。

2. 冰雪旅游研究现状

当前冰雪旅游研究涵盖基础理论与应用实践两大维度，整体呈现“定性研究

为主导、定量研究刚起步”的特征，研究内容聚焦四大方向：

（1）资源开发与产业融合

甘静^[3]以吉林省为案例，系统探讨“冰雪+文化”“冰雪+生态”的融合模式，提出通过“雾凇节结合满族民俗”“滑雪度假区联动自然保护区”等路径实现资源增值，其“产业融合需依托地域特色”的结论，为本研究构建“地域-主题”关联框架提供了理论支撑；

（2）经济效应与生态平衡

张娜^[4]通过投入产出分析，发现东北地区冰雪旅游对当地 GDP 的贡献率达 3.2%，但同时指出“过度开发可能导致生态破坏”，强调经济效益与生态保护的平衡，这一观点为本文分析“冰雪景观”主题的地域差异提供了价值导向；

（3）游客感知与体验优化

王丹凤^[5]以长白山滑雪度假区为样本，通过 1200 份问卷调查提炼出游客核心感知维度——“自然景观”（权重 0.35）、“冰雪活动”（权重 0.28）、“服务质量”（权重 0.22），其识别的感知维度与本文“冰雪景观”“游客体验”等主题高度契合，但该研究依赖小样本调研，缺乏大规模文本数据的支撑；

（4）政策体系与传播效果

张瑞林^[6]通过对 107 份不同层级冰雪产业政策的文本编码，揭示了“国家—地方—产业”的三级政策体系，为本文分析“政策扶持”主题提供了政策框架参考，但未将政策文本与新闻报道中的政策解读主题关联，无法评估政策的媒体传播效果。

3. 新闻报道主题与内容分析研究

新闻报道作为冰雪旅游信息传播的核心载体，其主题框架与内容策略直接影响公众认知与产业发展，现有研究围绕三大维度展开：

（1）主题框架构建

李曦^[7]在旅游营销信息传播研究中提出，旅游新闻需围绕“目的地形象”“体验活动”“配套服务”三大核心主题，通过“核心主题+衍生信息”的框架实现信息精准传递，这一理论延伸至冰雪领域，意味着报道需紧扣“冰雪景观”“节庆活动”“文化融合”等核心要素，同时补充“交通住宿”“安全提示”等衍生信息；殷化全^[8]进一步指出，党报更倾向于“战略意义”“政策解读”等宏观主

题，社交媒体则聚焦“游客体验”“活动现场”等微观主题，为本文对比不同平台主题差异提供了关键依据。

（2）融媒体内容策略

殷化全^[8]通过对比报纸与短视频平台的旅游报道发现，传统媒体适合采用“深度报道”形式解读冰雪产业价值（如冰雪经济对乡村振兴的带动），新媒体则擅长通过“即时性、可视化”内容呈现冰雪活动细节（如滑雪动作教学、冰雕展打卡），两者形成功能互补；梁丹娜^[9]对《新闻联播》重大主题报道的研究验证了这一规律，其发现《新闻联播》对冰雪旅游的报道多采用“宏观叙事+微观案例”框架（如“国家冰雪战略+吉林冰雪小镇建设”），增强报道说服力与感染力。

（3）话语与认知关联

益影^[10]通过批评话语分析指出，新闻报道通过“主题选择”与“案例叙事”塑造公众认知，例如大量报道“普通人参与冰雪运动”的案例，可强化公众对“冰雪旅游普惠性”的认知；聚焦“冰雪旅游带动乡村就业”的主题，可构建“冰雪经济助力乡村振兴”的社会共识，这一理论为本文分析文本情感倾向与社会价值提供了重要视角。

4. 现有研究不足

综合现有成果，冰雪旅游文本分析领域存在三方面显著不足，也正是本项目的核心突破方向：

（1）技术应用单一且深度不足

现有研究多依赖词频统计或单一 LDA 模型，未融合预训练语言模型，专业术语识别率低（如“雪道等级”识别率仅 45%），且对“标题党”“广告”等噪声的鲁棒性弱，噪声文本会导致主题识别准确率下降超过 20%；

（2）主题体系碎片化且跨媒体对比缺失

未对冰雪旅游专属主题进行分类，对“冰雪+装备制造”“冰雪+赛事运营”等产业核心主题覆盖不足，同时忽视不同媒体平台的主题差异，未实证分析党报与社交媒体在主题选择、语言风格上的区别；

（3）多维度与多源数据融合薄弱

缺乏“主题—情感—地域—时间”四维联动分析，且未整合游客评论、企业

运营数据、政策文本等多源信息，无法建立“媒体报道—游客感知—产业实践”的关联闭环，研究结论对产业的指导价值受限。

（三）应用领域与场景

本项目成果可深度适配冰雪产业全链条主体的需求，应用场景覆盖政府决策、企业运营、媒体传播、学术研究四大领域：

1. 政府部门

适配省市级文旅局、发改委等部门的产业规划与监管需求。例如，黑龙江省文旅厅可通过“政策扶持”主题的季度分布数据，评估“冰雪+”政策在省内 13 个地市的落地传播效果；针对西南地区“节庆活动主题占比仅 0.14”的短板，深度指导云南、四川等地策划“冰雪民俗节”“高原冰雪嘉年华”等特色活动，推动区域冰雪产业的差异化发展。

2. 冰雪旅游企业

覆盖负责景区运营、装备制造、赛事承办等企业类型。哈尔滨冰雪大世界可基于“冰雪景观”主题的高关注度，进一步开发“冰雕夜游”“雪地实景演出”等衍生产品；广州融创雪世界可针对“设施体验差”的负面反馈（占比超 30%），优先升级造雪设备与雪道防护系统；滑雪装备企业可通过“冰雪装备”主题的时间演化数据，把握非冰雪季（Q2、Q3）技术研发报道高峰期，精准投放新产品研发动态。

3. 媒体机构

满足党报、社交媒体、行业期刊的差异化传播需求。黑龙江日报、辽宁日报、吉林日报可基于项目成果优化区域冰雪旅游报道策略，黑龙江日报可侧重“冰雪景观”主题（如哈尔滨冰雪大世界）的深度报道，强化本地核心冰雪资源推介；辽宁日报可聚焦“冰雪赛事”主题（如沈阳国际冰雪节赛事），提升区域赛事传播影响力；吉林日报可突出“冰雪民俗+生态”主题（如雾凇节结合满族民俗、长白山冰雪生态保护），挖掘地域特色内容；同时，三家党报可通过项目揭示的“区域主题差异”，协同策划跨省份冰雪旅游联动报道，增强东北冰雪产业整体传播效应。

4. 学术研究机构

为高校旅游管理、新闻传播学、数据科学等专业提供研究支撑。例如，研究团队可基于本项目的“LDA+BERT”模型框架，开展“夏季旅游文本挖掘”“红色旅游新闻主题演化”等延伸研究；同时，项目产出的“七大区域情感分布数据集”“冬奥会前后主题变化数据集”，可作为教学案例融入《文本挖掘》《旅游产业分析》等课程，提升学生的实践分析能力。

（四）主要工作内容

本项目以“冰雪旅游新闻文本精准挖掘与产业规律揭示”为核心目标，分四个阶段开展工作，形成“数据—模型—分析—应用”的完整闭环：

1. 数据采集与预处理阶段

基于大赛提供的数据集，提取 2021-2023 年黑龙江日报、辽宁日报、吉林日报三家党报的冰雪旅游新闻文本，共获取 219093 条原始数据。随后开展系统化预处理：采用 TF-IDF 余弦相似度（阈值 0.9）剔除 23 条重复文本；通过正则表达式匹配，过滤 153 条“标题党”文本与 12426 条广告文本；采用 Jieba 精确分词（结合 320 个专业术语的自定义领域词典）与 45 词条停用词表（含“的”“报道”等冗余词）完成文本标准化；提取“年份—季度”时间特征与“七大冰雪旅游区域”地域特征，最终构建 206491 条有效样本的结构化数据集。

2. 模型设计与训练阶段

一是“LDA+BERT”语义增强型主题抽取模型，通过困惑度与一致性分数交叉验证确定 LDA 最优参数（ $K=18$ 、 $\alpha=0.1$ 、 $\beta=0.01$ ），生成 18 类核心主题，BERT 层以 $2e-5$ 学习率、32batchsize 微调，提升专业术语语义关联；

二是“BERT+全连接层”情感分析模型，以 5000 条人工标注文本（Kappa 系数 0.85）为训练集，实现正面、负面、中立三分类；

三是“主题—情感—地域—时间”时空关联分析层，设计 Jensen-Shannon 散度计算、关键词共现分析等算法，挖掘多维度关联规律。

3. 规律挖掘与可视化阶段

地域维度，统计七大区域的文本占比与情感分布，生成地域-主题关联热力

图；时间维度，分析冬奥会前后（2022Q1 为分界）、冰雪季与非冰雪季的主题变化，绘制主题时间演化折线图；媒体维度，对比党报、社交媒体、行业期刊的主题差异，形成媒体传播格局分析报告。同时，采用 Tableau、Matplotlib 等工具实现分析结果可视化，确保成果直观易懂。

4. 成果转化与应用阶段

针对政府、企业、媒体不同需求，输出定制化成果。为政府部门提供《冰雪产业区域发展短板与政策建议报告》；为企业输出《冰雪旅游产品优化与风险管控指南》；为媒体机构制定《冰雪旅游信息协同传播策略方案》。同时，整理项目数据集与模型代码，形成可复用的“冰雪旅游文本挖掘工具包”，降低产业主体的应用门槛。

（五）项目创新点

1. 技术创新

突破传统单一模型局限，构建“LDA+BERT”混合模型，实现“双向赋能”——LDA 模型为 BERT 提供文本潜在主题的先验分布，帮助其聚焦冰雪领域核心语义；BERT 模型为 LDA 的词向量注入深层语义关联，将“雪道等级”与“初级道”“高级道”的语义相似度从 0.3 提升至 0.428，专业术语识别准确率较传统 LDA 提升 40%以上，同时增强模型对噪声的鲁棒性，标题党、广告文本对主题识别的干扰降低 30%。

2. 框架创新

构建“主题—情感—地域—时间”四维分析框架，突破传统单一维度分析局限。主题维度，参考“冰雪+产业”融合思路，构建“核心主题（冰雪景观、赛事）—衍生主题（交通、住宿）—关联主题（乡村振兴、生态）”三级分类体系；情感维度，量化不同区域、媒体的情感倾向；地域维度，对比七大区域的主题优势与短板；时间维度，揭示冬奥会与季节对主题演化的驱动作用，实现跨学科理论的深度融合。

3. 实践创新

整合冰雪旅游新闻文本、政策文本、产业统计数据三类数据，建立“文本挖

掘一政策验证—实践关联”闭环。例如，将“区域振兴”主题报道量与地方冰雪旅游收入交叉验证，发现相关性系数达 0.62，揭示媒体报道对产业的推动作用；同时，针对政府、企业、媒体的差异化需求，输出定制化报告与工具包，确保研究成果可直接落地应用。

二、解决方案

（一）方案设计理念与原则

本项目以“问题导向、技术适配、实践落地”为核心设计理念，遵循三大原则：

数据驱动原则：以大规模真实文本数据为基础，通过系统化预处理确保数据质量，避免“小样本偏差”，确保模型训练与分析结果的可靠性；

技术适配原则：根据冰雪旅游文本的特点选择适配技术，例如针对专业术语多的特征，融合 LDA 与 BERT 模型；针对情感模糊性问题，采用双向 Transformer 架构的 BERT 模型，确保技术与需求高度匹配；

实践导向原则：方案设计全程围绕产业痛点，从政府、企业、媒体的实际需求出发，确保模型成果可转化、分析结论可落地，避免“技术空转”。

基于上述理念与原则，本项目采用“数据层—模型层—分析层—应用层”的四层架构设计，各层既相互独立又协同联动：数据层为整个方案提供高质量输入，模型层解决文本挖掘的核心技术问题，分析层揭示产业发展规律，应用层将规律转化为可操作的决策建议，形成完整的技术—实践链路。

（二）方案核心功能

本项目方案具备五大核心功能，覆盖冰雪旅游文本挖掘全流程需求：

1. 文本智能清洗功能

自动完成重复文本剔除、噪声过滤、格式标准化，支持自定义去重阈值（如 TF-IDF 余弦相似度 0.8-0.95 可调）与噪声匹配规则（可新增“诱导点击”“虚假宣传”等噪声类型），处理效率达 10 万条/小时，数据洁净度提升至 94.3%。该功能通过先进的自然语言处理技术，精准识别并剔除冗余内容，确保每一条信

息的独特性。同时，采用多层次的噪声过滤机制，有效屏蔽各种干扰信息，包括但不限于虚假广告、误导性链接和低质量内容，从而保证数据的纯净度和可靠性。在格式标准化方面，系统能够自动调整文本的排版和结构，使其符合预设的标准格式，提高后续分析和应用的便利性。此外，用户可以根据具体需求灵活调整去重阈值和噪声匹配规则，以适应不同场景下的数据清洗要求。整体而言，该功能不仅显著提升了数据处理的速度和效率，还大幅提高了数据的质量和可用性，为各类数据分析和决策提供了坚实的基础；

2. 主题自动提取与分类功能

可自动识别“政策扶持”“冰雪景观”“冰雪赛事”等 18 类核心主题，包括但不限于政府发布的相关扶持政策、冰雪景观的设计与建造细节、各类冰雪赛事的组织与管理流程。支持主题数量动态调整，并能输出每个主题的高频词、权重分布，如“政策扶持”主题下的“补贴”、“税收优惠”、“专项资金”等关键词及其出现频率和重要性排序。主题覆盖率达 88%，确保涵盖从冰雪产业链上游的研发设计到下游的市场推广各个环节的主题识别需求，满足产业全链条主题识别需求；

3. 情感精准分类功能

实现文本情感三分类（正面、负面、中立），支持批量处理与单条查询，准确率达 89.3%，精确率与召回率均超 88%。系统能够细致分析每条文本，捕捉其中细微的情感变化，提供详尽的情感概率分布，帮助用户精准把握情感倾向的强弱程度。无论是社交媒体评论、产品评价还是新闻报道，该系统都能高效处理，确保每一条信息的情感分析结果都具有高度可信度和实用性；

4. 多维度关联分析功能

支持“主题—情感—地域”“主题—时间”“地域—情感”等多维度组合分析，可生成关联热力图、趋势折线图、对比柱状图等可视化结果，直观呈现区域差异、时间演化、媒体特征等规律。通过这些图表，用户可以清晰地看到不同地区在特定主题下的情感分布，例如在某个城市中，新闻报道对某一事件的正面或负面情绪占比。同时，趋势折线图能够展示某一主题在不同时期的情感变化，帮助理解公众情绪随时间推移的变化趋势。对比柱状图则能直观比较不同地域在同

一主题上的情感强度，揭示出区域间的显著差异。这些丰富的可视化工具不仅增强了数据的可读性，还为深入分析提供了有力的支持；

5. 定制化报告生成功能

内置政府、企业、媒体三类模板，用户可根据需求选择模板，系统自动整合分析数据，生成包含数据支撑、规律总结、建议方案的定制化报告，报告生成时间缩短至 30 分钟/份。

（三）关键技术与实现路径

1. 文本预处理技术

将文本标题与正文合并，通过 TF-IDF 算法计算词汇权重，生成文本向量；采用余弦相似度公式（ $\cos\theta=A \cdot B/(|A| \times |B|)$ ）计算两条文本的相似度，设定阈值 0.9，剔除高度重复文本。该技术可有效避免同一政策解读、景区推介文章在多个平台转载导致的主题重复计数问题，去重准确率达 99.9%。

针对“标题党”与广告文本的语言特征，构建两类正则表达式库：标题党库包含“震惊、必看、惊人、重磅、揭秘、罕见”等 12 个高频煽动性词汇；广告库包含“优惠活动、购票链接、购买点击、限时折扣、扫码关注”等 8 个商业推广词汇。通过 Python 的 re 模块进行匹配，噪声识别准确率达 92% 以上，误判率低于 3%。

梳理冰雪旅游政策文件、行业报告、高相关文献，收集“冰雪设施”“冰雪赛事”“冰雪活动”等类别共 320 个专业术语，构建自定义领域词典；将词典加载至 Jieba 分词工具，采用“词典匹配优先”机制，确保“雪道等级”“冰壶赛事”等术语不被错误切分，分词准确率从 97% 提升至 99.2%。

2. 主题抽取与情感分析技术

采用吉布斯采样算法进行参数估计，通过“困惑度+一致性分数”交叉验证确定最优参数，主题数 $K=18$ （ $K=18$ 时困惑度 2800、一致性 0.51，均优于 $K=15-20$ 其他取值）、 $\alpha=0.1$ 、 $\beta=0.01$ 。通过该参数设置，LDA 模型生成的主题语义连贯性显著提升，“冰雪赛事”主题的高频词语义关联度达 0.8 以上。

采用中文 BERT-base 模型（12 层 Transformer 编码器、768 维词向量），以 LDA 输出的每个主题前 10 个高频词为输入，通过自注意力机制加权聚合生成主

题语义向量 ($Z_k = \text{Attention}(\text{BERT}(w_1), \dots, \text{BERT}(w_{10}))$)；构建损失函数 $L = -\log P(Z_k | \text{主题词})$ ，以 $2e-5$ 学习率、32batchsize 在冰雪旅游数据集上微调 5 个 epoch，模型收敛后，专业术语的语义关联度提升 42%以上。

采用“BERT 编码器+全连接层+Softmax”结构，输入文本长度统一设为 128（基于冰雪旅游文本平均长度统计确定）；BERT 编码器输出 768 维[CLS]向量作为文本整体语义表示；全连接层将 768 维向量映射为 3 维向量，Softmax 函数转换为概率分布。以 5000 条人工标注文本（Kappa 系数 0.85）为训练集，采用 AdamW 优化器、交叉熵损失函数训练 3 个 epoch，模型在验证集上的准确率达 89.3%，显著优于传统 SVM（78.5%）与 CNN（82.1%）模型。

3. 时空关联分析技术

将数据按“年份—季度”划分为 12 个时间片（2021Q1—2023Q4），对每个时间片运行 LDA-BERT 模型生成主题分布序列 θ_t ；采用 Jensen-Shannon 散度 ($\text{JSD}(P, Q) = 0.5 \times \text{KL}(P, M) + 0.5 \times \text{KL}(Q, M)$ ，其中 $M = (P + Q) / 2$) 衡量相邻时间片主题分布的差异，JSD 值越大表示主题变化越显著。通过该技术，清晰识别出冬奥会（2022Q1）与冰雪季对主题演化的驱动作用，如 2022Q1“冰雪赛事”主题 JSD 值达 0.32，是全年最大变化值。

对负面情感文本进行关键词提取，统计高频负面关键词（如“拥堵”“设施老化”“票价高”）的共现频次，构建共现网络；通过节点度、中介中心性等指标识别核心负面诱因，发现 82%的负面文本与“拥堵”“设施老化”“票价高”相关，37%涉及景区安全，为企业风险管控提供精准方向。

统计七大区域在 18 类核心主题上的占比，构建“地域—主题”矩阵，并生成热力图，颜色越深表示主题占比越高，直观呈现区域主题优势与短板，如东北地区“冰雪景观”主题颜色最深，西南地区“节庆活动”主题颜色最浅。

（四）实现过程与关键步骤

1. 数据生成与处理

（1）数据采集

基于大赛提供的数据集，直接提取其中 2021 年 1 月—2023 年 12 月黑龙江日报、辽宁日报、吉林日报的冰雪旅游新闻文本，共获取 219093 条原始数据；

数据字段保留标题、正文、发布时间、来源平台、提及地域等核心信息。

（2）数据清洗

第一步去重，使用 Scikit-learn 库的 TfidfVectorizer 将文本转换为 TF-IDF 向量，计算余弦相似度，剔除相似度 ≥ 0.9 的重复文本，剩余 219070 条；

第二步噪声过滤，通过 re 模块匹配标题党与广告文本，剔除 153 条标题党、12426 条广告，最终保留 206491 条有效样本；

第三步格式统一，将文本编码统一为 UTF-8，处理乱码、换行符等问题，确保数据格式规范。

（3）文本标准化

采用 Jieba 精确分词处理文本，加载 45 词条自定义停用词表（含“的”“了”“报道”等）过滤冗余词汇；构建 320 个专业术语的领域词典，加载至 Jieba 提升分词准确性；对分词后的文本进行词频统计，生成文档一词矩阵，为后续建模提供输入。

（4）特征提取

时间特征方面，通过 re 模块提取文本中的日期信息（如“2023 年 2 月”“2023-2-15”），采用 Python 的 datetime 模块转换为“年份—月份”，再映射为“年份—季度”（如 2023-02→2023Q1）；

地域特征方面，采用 Jieba 的专名识别功能提取地域实体（如“哈尔滨”“北京”），构建“地域—区域”映射表（如“哈尔滨”→东北地区、“北京”→京津冀地区），完成地域分类。

2. 数据组织与管理

（1）数据存储

采用 MySQL 数据库存储结构化数据，设计四张核心表：原始数据表（存储标题、正文、发布时间等原始信息）、清洗后数据表（存储去重、噪声过滤后的文本）、标准化数据表（存储分词结果、停用词过滤后的文本）、特征数据表（存储时间特征、地域特征、主题标签、情感标签），表间通过“文本 ID”关联，确保数据完整性与一致性。

（2）数据分区

按“时间片”（2021Q1-2023Q4）、“地域”（七大区域）、“媒体类型”

（党报、社交媒体、行业期刊）对数据进行分区存储，例如在 MySQL 中创建“2022Q1_东北_党报”“2023Q4_西南_社交媒体”等分区表，提升数据查询与分析效率，单分区数据查询时间缩短至 0.5 秒以内。

（3）数据质量管控

建立数据质量评估指标体系，包括数据完整性（字段缺失率 $\leq 1\%$ ）、准确性（地域分类错误率 $\leq 2\%$ 、时间标准化错误率 $\leq 1\%$ ）、一致性（同一文本的主题标签、情感标签在不同表中一致）；每周开展一次数据质量检测，发现问题及时修复，确保后续建模与分析的可靠性。

3. 模型训练与优化

（1）LDA 模型训练

使用 Gensim 库实现 LDA 模型，输入文档—词矩阵，设置迭代次数 1000 次；通过循环测试 $K=15-20$ 的取值，计算每个 K 值的困惑度与一致性分数，确定最优主题数 $K=18$ ；调整 $\alpha=0.1$ 、 $\beta=0.01$ ，训练模型生成主题—词分布与文档—主题分布，提取 18 类核心主题及其高频词。

（2）BERT 语义增强层训练

使用 PyTorch 框架加载中文 BERT-base 预训练模型，将 LDA 输出的每个主题前 10 个高频词作为输入数据；设置学习率 $2e-5$ 、 $batchsize=32$ ，训练 5 个 epoch；通过计算“雪道等级”与“初级道”“高级道”的余弦相似度，验证语义增强效果，确保相似度提升至 0.428 以上。

（3）情感分析模型训练

划分 5000 条人工标注文本为 8:2 的训练集与验证集；使用 HuggingFace 的 Transformers 库构建“BERT+全连接层”模型，设置文本长度 128、学习率 $2e-5$ 、 $batchsize=32$ ，采用交叉熵损失函数训练 3 个 epoch；在验证集上评估模型性能，确保准确率 $\geq 89\%$ 、精确率与召回率 $\geq 88\%$ ，若未达标则调整学习率或增加训练数据，重新训练。

4. 结果分析与可视化

（1）多维度分析

地域维度，统计七大区域的文本占比、主题占比、情感占比，分析区域差异，如华北地区可能更关注冰雪运动的发展，而华南地区则更多讨论气候对冰雪活动

的影响；时间维度，对比冬奥会前后、冰雪季与非冰雪季的主题变化，揭示演化规律，例如冬奥会期间，冰雪运动相关话题激增，而非冰雪季则更多关注夏季运动和休闲活动；情感维度，分析负面情感的地域分布与核心诱因，如某些地区由于基础设施不足或天气原因导致负面情绪较多，核心诱因可能是交通不便、设施损坏或服务质量差等。




图 1 冬奥会前后分界主题占比变化对比




图 2 冰雪季与非冰雪季主题占比差异

(2) 可视化实现

绘制主题时间演化折线图，展示每个主题在不同时间段内的变化趋势，通过颜色区分不同的主题，使用户能够清晰地观察到各个主题随时间的兴衰。同时，绘制情感分布表，呈现各地情感分布情况。




图 3 冰雪旅游新闻报道主题随时间演化趋势

表 1 七大区域情感分布

区域	正面占比	负面占比	中立占比	核心情感特征
东北地区	68.2%	12.5%	19.3%	正面占比最高，情感最积极
京津冀地区	65.7%	14.1%	20.2%	正面占比高，负面集中于拥堵
西北地区	62.3%	15.8%	21.9%	正面占比中等，负面涉设施
华北地区	60.1%	16.5%	23.4%	情感较平稳
华东地区	58.2%	17.8%	24.0%	负面占比上升，涉服务质量

区域	正面占比	负面占比	中立占比	核心情感特征
华南地区	55.4%	19.2%	25.4%	负面占比高，涉人造雪体验
西南地区	52.7%	21.3%	26.0%	负面占比最高，情感最消极

绘制地域—主题关联热力图，通过颜色深浅展示不同地域与各主题之间的关联强度，帮助用户快速识别哪些地域对特定主题的关注度最高。热力图中的颜色渐变和标签标注进一步增强了数据的可读性。




图 4 七大区域冰雪旅游新闻报道主题占比热力图

制作交互式可视化仪表板，支持用户通过点击、筛选查看不同维度的分析结果。例如，点击“西南地区”，仪表板会自动更新，显示该区域的主题占比、情感分布、负面诱因等详细信息。用户还可以通过下拉菜单或过滤器选择其他地区或时间段，实时获取相应的数据分析结果。仪表板的设计注重用户体验，提供动态图表、数据提示和多视图联动功能，确保用户能够方便快捷地进行深入分析。

(3) 结果验证

通过“人工抽样验证”与“多源数据交叉验证”确保分析结果可靠。人工抽

样方面，随机抽取 1000 条文本逐条审核，细致评估每一条文本的主题标签与情感标签的准确性，确保准确率需 $\geq 90\%$ ，以保证数据的精确性和可靠性。多源数据交叉验证方面，将“冰雪景观”主题的报道量与东北、京津冀地区的知名景区游客量数据进行详细对比分析，通过统计学方法计算相关性系数，确保相关性系数 ≥ 0.5 ，从而验证分析结果的合理性和科学性。

（五）项目实施保障

团队保障：组建三人核心项目团队，成员身兼多职确保项目高效推进。其中 1 名成员负责自然语言处理与模型构建优化，同时承担部分数据预处理工作；1 名成员主攻数据深度分析与可视化，兼任项目管理，把控进度与质量；1 名成员通过多方查询，提供产业需求指导，并协助成果转化，实现技术与产业需求的深度融合。

进度保障：制定详细的项目进度计划，将四个阶段（数据预处理、模型训练、分析可视化、成果转化）分解为多个具体任务，明确每个任务的负责人、完成时间、交付成果；每周召开一次项目例会，跟踪进度、解决问题，确保项目按计划完成。

风险保障：识别项目实施过程中的潜在风险，包括数据采集量不足、模型训练效果不佳、成果落地困难等，并制定应对措施。例如，针对“模型效果不佳”风险，准备多套模型方案，确保项目顺利推进。

三、应用价值

（一）经济效益

1. 推动冰雪产业规模扩张与结构优化

本项目成果可帮助政府精准识别不同区域冰雪产业的发展短板，针对性制定差异化扶持政策。例如针对西南地区在冰雪节庆活动方面的发展不足，指导当地结合地域特色策划专属冰雪活动，推动当地冰雪旅游收入合理增长；帮助东北等传统冰雪旅游区域的企业，依托“冰雪景观”主题的高关注度，开发特色衍生产品，提升游客消费潜力。同时，助力全国冰雪产业突破季节限制，从“冬季经济”

向“四季经济”转型，提高非冰雪季业务对产业整体收入的贡献度，推动产业规模向更高层级迈进。

2. 降低企业运营成本与风险损失

企业可借助项目输出的负面情感归因分析结果，精准定位运营中的核心问题并针对性解决。例如热门景区可参考优化客流管理模式（如推行分时段预约），缓解节假日客流压力，减少游客投诉，降低投诉处理与品牌修复的相关成本；南方人造冰雪景区可聚焦“设施体验”相关反馈，优先升级关键设备，避免盲目投入，提升设备升级的实际效益。此外，企业还能依托项目挖掘的主题时间演化规律，把握非冰雪季产业关注重点（如冰雪装备制造），合理安排研发与生产计划，减少库存积压，提高资源利用效率。

3. 提升媒体传播效益与广告价值

媒体机构可基于项目揭示的“党报+社交媒体+行业期刊”协同传播特征，优化传播资源分配。例如党报侧重冰雪产业政策解读与宏观价值传递，社交媒体聚焦游客真实体验与活动场景分享，形成功能互补的传播格局，提升整体传播效率与信息触达范围；针对西南、华南等冰雪旅游关注度较低的区域，媒体可结合项目挖掘的区域潜在需求，增加特色冰雪内容报道，吸引区域内潜在游客，提升广告投放的精准性，帮助广告投资商获得更优的投入回报。

4. 带动相关产业发展与就业增长

项目成果在推动冰雪产业自身发展的同时，将进一步辐射餐饮、住宿、交通、冰雪装备制造等上下游相关产业。例如西南地区通过策划冰雪节庆活动，可带动当地餐饮、住宿等配套产业活力提升；冰雪装备制造企业可参考项目挖掘的“冰雪装备”主题技术研发方向，优化产品设计与推广策略，提升新产品市场接受度，进而带动产业规模扩大。产业规模的扩张将创造更多就业岗位，助力区域就业稳定，为稳就业目标的实现提供支撑。

（二）社会效益

1. 提升公众冰雪旅游体验与满意度

项目通过精准识别冰雪旅游中的负面体验诱因（如客流拥堵、设施老化、安

全隐患等），为景区优化服务提供明确方向。例如推动景区完善预约机制、加强设施日常检修、增设安全提示标识等，减少影响游客体验的问题，缩短游客非游玩等待时间，降低安全事故发生风险，让公众在冰雪旅游中获得更优质的消费体验，提升整体满意度与消费获得感。

2. 促进冰雪运动普及与健康中国建设

依托项目构建的媒体协同传播格局，党报可深入传递冰雪产业政策导向与冰雪运动的健康价值，社交媒体可分享普通人参与冰雪运动的真实场景与体验，行业期刊可普及冰雪运动知识与技能，多渠道结合提升公众对冰雪运动的认知度与参与意愿。助力“三亿人参与冰雪运动”目标的深化推进，推动全民健身理念落地，为健康中国建设提供助力，减少因缺乏运动导致的慢性病风险，节约医疗资源。

3. 推动区域均衡发展 with 乡村振兴

针对西南、华南等新兴冰雪旅游区域的发展短板，项目可提供“特色 IP 打造+配套服务升级”的针对性建议，帮助这些区域挖掘自身优势（如高原冰雪、民族文化融合等），培育冰雪旅游特色品牌，缩小与东北、京津冀等传统冰雪区域的发展差距。例如云南等区域可依托“高原冰雪+民族文化”打造专属 IP，带动周边乡村发展民宿、餐饮等配套产业，提升乡村旅游收入与村民收入水平，为乡村振兴与共同富裕目标的实现提供动力。

4. 传播冰雪文化与增强文化自信

项目成果可引导媒体增加“冰雪+文化”主题的报道内容，例如东北的冰雪民俗、北京的冬奥文化等，让公众更深入地了解我国冰雪文化的丰富内涵与独特魅力，增强对本土冰雪文化的认同。同时，通过国际媒体的转载或合作传播，向全球展示中国冰雪文化的特色与冰雪经济的发展成就，提升中国冰雪文化的国际影响力，进一步增强国民的文化自信与民族自豪感。

5. 强化产业监管与规范发展

政府部门可借助项目输出的“政策扶持”主题传播数据，评估冰雪产业相关政策的落地传播效果，及时发现政策执行中的问题并调整优化方向；通过项目挖掘的负面情感数据，精准识别产业发展中的突出问题，针对性加强监管力度，规

范市场经营秩序，保障消费者合法权益，推动冰雪产业朝着健康、可持续发展的方向。

（三）学术价值

1. 丰富旅游文本挖掘理论体系

本项目构建的“LDA+BERT”语义增强型主题抽取模型，突破传统模型的语义表示局限，为旅游文本挖掘提供了新的技术范式；建立的“主题—情感—地域—时间”四维分析框架，推动旅游文本研究从“单一维度”向“多维度联动”转型，丰富了旅游管理与自然语言处理交叉领域的理论成果。

2. 填补冰雪旅游文本专属主题体系空白

项目首次构建包含 18 类核心主题的冰雪旅游专属主题分类框架，覆盖“政策扶持”“冰雪景观”“冰雪赛事”“装备制造”等产业全链条主题，特别是对“冰雪+乡村振兴”“冰雪+生态保护”等新兴融合主题的梳理，填补了现有研究的空白，为后续冰雪旅游文本分析提供了标准化的主题参考。

3. 提供多源数据融合研究范例

项目以比赛提供的冰雪旅游新闻文本数据为核心基础，进一步整合冰雪产业政策文本、区域冰雪旅游统计数据两类补充信息，构建“核心文本数据+政策参考数据+产业实践数据”的多源数据体系，并基于此建立“文本挖掘结论—政策落地验证—产业实践关联”的研究闭环。该闭环有效解决了传统旅游文本研究中“仅依赖单一文本数据、结论与政策执行、产业实践脱节”的问题，既依托比赛数据保障了文本挖掘的基础样本质量，又通过补充数据实现了“理论分析—实践验证”的双向支撑，为旅游领域多源数据融合研究提供了可参考的实践范例，推动旅游研究从“单一数据驱动”向“多源数据协同支撑”转变。

附录

参考文献

- [1] 陈涛.基于主题的个性化新闻推荐系统的设计与实现[D].浙江大学,2023.DOI:10.27461/d.cnki.gzjdx.2023.001660.
- [2] 杨春梅,赵原,徐西帅,等.基于网络文本数据分析的冰雪旅游游客满意度研究——以哈尔滨为例[J].企业经济,2022,41(03):133-140.DOI:10.13529/j.cnki.enterprise.economy.2022.03.013.
- [3] 甘静.吉林省冰雪旅游开发决策研究[J].鸡西大学学报,2011,11(11):77-79.DOI:10.16792/j.cnki.1672-6758.2011.11.037.
- [4] 张娜.东北地区冰雪旅游经济效应及调控研究[D].东北师范大学,2012.
- [5] 王丹凤.长白山冰雪旅游目的地游客感知形象测度及提升策略研究[D].吉林外国语大学,2025.DOI:10.27833/d.cnki.gjlhw.2025.000294.
- [6] 张瑞林,程美超,李凌.我国冰雪产业政策层级性特征与未来展望——基于 107 份不同层级冰雪产业政策的文本分析[J].山东体育学院学报,2024,40(03):10-19.DOI:10.14104/j.cnki.1006-2076.2024.03.002.
- [7] 李曦.旅游目的地新媒体整合营销传播研究[D].南开大学,2014.
- [8] 殷化全.融媒体时代重大主题报道策略探析[J].新闻世界,2025,(07):63-65.DOI:10.19497/j.cnki.1005-5932.2025.07.019.
- [9] 梁丹娜.《新闻联播》主题报道实践研究[D].南昌大学,2012.
- [10] 益影.批评话语分析视域下《论据与事实报》“车臣”主题报道的社会认知分析[D].大连外国语大学,2023.DOI:10.26993/d.cnki.gslyc.2023.000419.